

十月算法班第三讲

管老师

七月在线

Oct, 2016

主要内容 (上)

- 优化与凸优化简介
 - 优化问题基本形式
 - 凸优化问题基本形式
 - 凸优化的应用
- 凸集合与凸函数基本概念
 - 凸集合与凸函数的关系
 - 凸集合与凸函数的性质对应
- 凸集分离定理
 - 凸集分离定理
- 共轭凸函数
 - 共轭凸函数
- 凸优化问题举例

主要内容 (下)

- 共轭函数
 - 共轭函数
- 对偶问题
 - 拉格朗日对偶函数
 - 拉格朗日对偶问题
 - 共轭函数与拉格朗日对偶函数
- 对偶性
 - 弱对偶性与强对偶性
 - 强对偶性成立的几种情况
 - 凸优化问题求解 (KKT)
- 应用举例
 - 支持向量机 (SVM) 的最简单形式
- 总结寄语 (数学部分)

- 本节课常用数学记号

V, W 向量空间

v, w 向量

$\mathbb{R}^n, \mathbb{R}^m$ 实坐标空间

α, β V 和 W 的基

$T: V \rightarrow W$ 向量空间 V 到 W 的线性映射

$A_{\alpha, \beta}(T)$ 线性映射 T 在 α 和 β 这两组基下的矩阵

$G(v_1, v_2)$ 内积空间 V 上的内积

H_α G 在基 α 下的矩阵形式

优化与凸优化简介

优化问题

优化问题的一般形式

最小化: $f_0(x)$

条件: $f_i(x) \leq b_i, i = 1, \dots, m.$

其中 $f_0(x)$ 为目标函数, 条件里的不等式是限制条件.

优化与凸优化简介

举例:

极大似然估计

如果 $L(\mu, \sigma)$ 是一个极大似然估计问题中的似然函数, 其中 μ, σ 分别是期望和方差, 那么极大似然估计的问题转化为

$$\text{最小化: } -L(\mu, \sigma)$$

$$\text{条件: } \sigma \geq 0$$

最小二乘

如果 $A_{n \times k}$ 是一个矩阵, $b \in \mathbb{R}^n$ 是一个向量, 对于 $x \in \mathbb{R}^k$

$$\text{最小化: } f_0(x) = \|Ax - b\|^2$$

优化与凸优化简介

凸优化问题

凸优化问题的一般形式

最小化: $f_0(x)$

条件: $f_i(x) \leq b_i, i = 1, \dots, m.$

其中 $f_0(x)$ 为目标函数, 条件里的不等式是限制条件.

- 凸优化问题的条件, f_0, f_1, \dots, f_m 都是凸函数.
- 凸优化问题的特点, 局部最优等价于全局最优.
- 凸优化问题的求解, 几乎总有现成的工具来求解.

优化与凸优化简介

凸优化的应用

- 凸优化问题逼近非凸优化问题，寻找非凸问题的初始点
- 利用对偶问题的凸性给原问题提供下界估计
- 凸优化问题可以给非凸问题带来一些启发

凸集合与凸函数

凸集合定义

如果一个集合 Ω 中任何两个点之间的线段上任何一个点还属于 Ω , 那么 Ω 就是一个凸集合.i.e.

$$\lambda x_1 + (1 - \lambda)x_2 \in \Omega, \forall x_1, x_2 \in \Omega, \lambda \in (0, 1)$$

凸函数定义

如果一个函数 f 定义域 Ω 是凸集, 而且对于任何两点. 以及两点之间线段上任意一个点都有

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

$$\forall x_1, x_2 \in \Omega, \lambda \in (0, 1)$$

凸集合与凸函数

凸集合与凸函数

函数的上境图

假设 f 是一个定义在 Ω 上的函数, 区域 $\{(x, y) : y \geq f(x), \forall x \in \Omega\}$ 就是 f 的上境图.

上境图就是函数图像上方的部分区域.

凸集合与凸函数

一个函数是凸函数当且仅当 f 的上境图是凸集合.

凸集合与凸函数有很多相对应的性质可以由这个结论来进行链接。

凸集合与凸函数

凸集合与凸函数

凸组合

对于任何 n 个点 $\{x_i\}_{i=1}^n$, 以及权重系数 $\{w_i\}_{i=1}^n$. 若权重系数非负 $w_i \geq 0$ 而且 $\sum_{i=1}^n w_i = 1$, 则线性组合

$$S = \sum_{i=1}^n w_i x_i$$

为一个凸组合.

凸组合的物理意义可以理解成 n 个重量为 w_i 的点的整体重心.

凸集合与凸函数

凸集合与凸函数

集合的凸包

n 个点 $\{x_i\}_{i=1}^n$ 的全部凸组合就构成 $\{x_i\}_{i=1}^n$ 的凸包.

函数的凸闭包

如果 C 是函数 f 的上境图, \overline{C} 是 C 的凸包, 那么以 \overline{C} 为上境图的函数称为 f 的凸闭包.

凸集合与凸函数

集合的凸包的性质

若 \overline{C} 是 C 的凸闭包, 那么

- $C \subset \overline{C}$
- C 的支撑平面也是 \overline{C} 的支撑平面, 反之亦然.

函数的凸闭包的性质

若 g 是 f 的凸闭包, 那么

- $g \leq f$
- $\inf\{g\} = \inf f$

凸集合与凸函数的对应性质 (凸组合)

凸集合性质

假设 Ω 是一个凸集合, 那么 Ω 任何子集的凸包仍包含于 Ω .

凸函数性质: 琴生 (Jensen) 不等式

如果 $f: \Omega \rightarrow \mathbb{R}$ 是一个凸函数, 则对于任何 $\{x_i \in \Omega\}_{i=1}^n$, 以及凸组合 $\sum_{i=1}^n w_i x_i$ 都有

$$\sum_{i=1}^n w_i f(x_i) \geq f\left(\sum_{i=1}^n w_i x_i\right)$$

话外篇：琴生 (Jensen) 不等式的推论

很多常用的不等式都是琴生不等式的推论，事实上，大部分不等式要么来自于 $x^2 \geq 0$ 要么来自于琴生不等式。

算数集合平均不等式

对于正数 a_1, \dots, a_n

$$\frac{\sum_{i=1}^n a_i}{n} \geq \left(\prod_{i=1}^n a_i \right)^{\frac{1}{n}}$$

柯西不等式

$$\left(\sum_{i=1}^n a_i^2 \right) \left(\sum_{i=1}^n b_i^2 \right) \geq \left(\sum_{i=1}^n a_i b_i \right)^2$$

凸集合与凸函数

凸集合与凸函数的对应性质 (集合相交)

凸集合性质

任意多个凸集合的交集仍是凸集合.

凸函数性质

- 任意多个凸函数的逐点上确界仍是凸函数.
- 固定一个凸函数的若干个变量, 所得的函数仍然是凸函数
- 凸函数的 `sublevel set` 都是凸集合.

凸集合与凸函数

凸集合与凸函数的对应性质 (线性组合)

凸集合性质

假设 $T: V \rightarrow W$ 是一个线性映射, 则

- 若 Ω_V 是 V 中的凸集合, 则 $\Omega_W = T(\Omega_V)$ 是 W 中的凸集合.
- 若 Ω_W 是 W 中的凸集合, 则 $\Omega_V = T^{-1}(\Omega_W)$ 是 V 中的凸集合.

凸函数性质

- 凸函数的非负线性组合仍是凸函数, f_1, \dots, f_k 是凸函数, 而且 $w_i \geq 0$, 则 $\sum_{i=1}^k w_i f_i$ 也是凸函数.
- 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, $A \in \mathbb{R}^{n \times m}, b \in \mathbb{R}^n$, 那么复合函数 $g(x) = f(Ax + b)$ 还是凸函数.

凸集合与凸函数

凸集合与凸函数的对应性质 (微分)

凸集合性质

- 若凸集合 Ω 的边界 C 是一个可微曲线, 则 C 在任意一点上的切线 (平面) 都是这个凸集合的支撑线 (平面)
- 若凸集合 Ω 的边界 C 是一个二阶可微曲线, 则 C 在任意一点上的曲率向量都指向 Ω 内部.

曲率向量的物理意义是加速方向或者受力方向.

凸函数性质

- 若一个凸函数一阶可微, 那么凸函数的一阶近似不大于函数本身.i.e.

$$f(x) \geq f(x_0) + (\nabla f(x_0))^T \cdot (x - x_0)$$

- 若一个凸函数二阶可微, 那么这个函数的二阶导数 (Hesssen 矩阵) 非负 (半正定) .

凸集合与凸函数

凸集合与凸函数的对应性质 (光学投影)

凸集合性质

- 若 Ω 是凸集合, 那么 Ω 在任何一个平面上的投影仍是凸集合 (平行光源投影)
- 若 $\Omega \subset \mathbb{R}^n$ 是凸集合, 那么

$$\Omega_{\hat{n}} = \{(x_1/x_n, \dots, x_{n-1}/x_n, 1) : (x_1, \dots, x_n) \in \Omega \text{ 且 } x_n \neq 0\}$$

也是凸集合.(点光源投影)

- 若 $\Omega \subset \mathbb{R}^n$ 是一个凸集合, 那么椎体 $tx : x \in \Omega, t \in \mathbb{R}_+$ 也是个凸集合.(点光源)

凸集合与凸函数的对应性质 (光学投影)

凸函数性质

- 若 $f(x, y)$ 是凸函数, 那么 $g(x) = \inf_{(x, y) \in \Omega} f(x, y)$, 也是凸函数
- 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, 那么 $g(x, t) = tf(x/t): \mathbb{R}^{n+1} \rightarrow \mathbb{R}$ 也是个凸函数.

凸集合与凸函数

凸集分离定理

凸集分离定理

若 C, D 分别为 \mathbb{R}^n 中的两个不交的非空凸集合, i.e. $C \cap D = \emptyset$, 则一定存在向量 $a \in \mathbb{R}^n$ 以及实数 $b \in \mathbb{R}$ 使得任何 $x_C \in C, x_D \in D$ 有 $a^T x_C \leq b$ 以及 $a^T x_D \geq b$.

定理中不等式的几何意义在于 C, D 分别位于超平面 $a^T x = b$ 的两边.

凸集分离定理

凸集分离定理

证明

分情况讨论：如果 C 是一个独点集 $\{p\}$ ，那么考虑集合 $\{|p - q| : q \in D\}$. 因为点之间的距离是非负数，所以根据确界原理存在一个序列 $\{q_i \in D\}_{i=1}^{\infty}$. 使得

$$\lim_{i \rightarrow \infty} |p - q_i| = \inf\{|p - q| : q \in D\}$$

而另一方面有界序列一定存在收敛子序列，所以可以假定

$$\lim_{i \rightarrow \infty} q_i = q_{\infty}.$$

(1) 如果 $p \neq q_{\infty}$ ，则令 $a = q_{\infty} - p, b = a^T(p + q_{\infty})/2$ ，我们得到

$$a^T p = a^T \left(-\frac{q_{\infty} - p}{2} + \frac{p + q_{\infty}}{2} \right) = -\frac{|a|^2}{2} + b \leq b$$

$$a^T q_{\infty} = a^T \left(\frac{q_{\infty} - p}{2} + \frac{p + q_{\infty}}{2} \right) = \frac{|a|^2}{2} + b \geq b$$

凸集分离定理

继续证明

此时对于任何一个 $q_0 \in D$, 考虑线段 $q_\infty + t(q_0 - q_\infty)$, 因为 $|q_\infty - p| = \inf\{|q - p| : q \in D\}$, 所以

$$f(t) = |q_\infty + t(q_0 - q_\infty) - p|^2 \geq |q_\infty - p|^2 = f(0), \forall t \in (0, 1)$$

所以 $f'(0) \geq 0$, 于是我们有

$$(q_\infty - p)^T (q_0 - q_\infty) \geq 0$$

也就是

$$a^T q_0 \geq a^T q_\infty \geq b$$

凸集分离定理

继续证明

(2) 如果 $p = q_\infty$, 那么选取序列 $\{p_j\}_{j=1}^\infty$, 使得 p_j 不在 D 的闭包里面. 那么根据上一种情况我们知道, 对每一个 j , 都存在着 a_j 使得 $a_j^T q \geq a_j^T p_j$. 因为 a_j 的长度无关紧要, 所以可以假设 a_j 都是单位向量。于是有界序列一定存在收敛子序列, 所以可以假定 a_j 收敛于一个单位向量 a_∞ . 那么对于任何一个 $q \in D$ 我们有

$$\begin{aligned} a_\infty^T p &= \lim_{j \rightarrow \infty} a_j^T p_j \\ &\leq \lim_{j \rightarrow \infty} a_j^T q \\ &= \lim_{j \rightarrow \infty} a_j^T q \\ &= a_\infty^T q \end{aligned}$$

令 $a = a_\infty, b = a_\infty^T p$. 即得所求.

凸集分离定理

继续证明

如果 C, D 是任意凸集合, 考虑集合 $C - D = \{x - y : p \in C, q \in D\}$. 那么不难证明 $C - D$ 还是一个凸集合 (作业). 而且零向量 $O \notin C - D$. 于是使用前面证明的独点集与凸集合的分离定理我们有, 存在一个向量 a 使得

$$a^T(p - q) \leq q^T O = 0$$

所以对于任意的 $p \in C, q \in D$, 都有

$$a^T q \geq a^T p$$

这时候令 $b = \sup\{a^T p : p \in C\}$, 既得所证。

共轭函数

共轭函数

如果 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个函数, 那么 f 的共轭函数

$$f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x))$$

其中 $f^*(y)$ 的定义域是使得等式右边有界的那些 y .

共轭函数的性质

- 共轭函数 f^* 是一个凸函数
- 如果 g 是 f 的凸闭包, 那么 $g^* = f^*$
- 如果 f 是一个凸函数, 那么 $f^{**} = f$

共轭函数的进一步性质

- $f(x) + f^*(y) \geq x^T y$
- 如果 f 是凸函数而且可微, 那么
 $f^*(y) = x^* T \nabla f(x^*) - f(x^*)$, 其中 x^* 满足 $\nabla f(x^*) = y$.
- 如果 $g(x) = f(Ax + b)$, 则 $g^*(y) = f^*(A^{-T}y) - b^T A^{-T}y$.
- 如果 $f(u, v) = f_1(u) + f_2(v)$, 那么 $f^*(w, z) = f_1^*(w) + f_2^*(z)$

共轭函数

对偶问题：拉格朗日对偶函数

考虑 \mathbb{R}^n 上的优化问题:

优化问题

最小化: $f_0(x)$

不等条件: $f_i(x) \leq b_i, i = 1, \dots, m$

等式条件: $h_i(x) = 0, i = 1, \dots, p$

定义域: $\mathcal{D} = \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i.$

请注意定义域 \mathcal{D} 指的是使得所有函数 f_i, h_i 有定义的区域。而可行域指的是定义域中满足不等条件与等式条件的那些点。本课中把这个优化问题称为原问题，优化点称为 x^* ，最优化值为 p^* 。

对偶问题：拉格朗日对偶函数

根据原函数与限制条件我们定义拉格朗日量 $L(x, \lambda, \nu) : \mathbb{R}^{n+m+p} \rightarrow \mathbb{R}$

拉格朗日量

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x),$$

根据拉格朗日函数我们定义拉格朗日对偶函数 $g(\lambda, \nu) : \mathbb{R}^{m+p} \rightarrow \mathbb{R}$

拉格朗日对偶函数

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \\ &= \inf_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \end{aligned}$$

拉格朗日量在数学与物理中有极为广泛的应用，感兴趣的同学可以在“信息几何学”，“理论力学”中找到它其他的应用。

对偶问题：拉格朗日对偶函数

对偶函数有如下重要性质

对偶函数为原问题提供下界

如果限制 $\lambda_i \geq 0, \forall i = 1, \dots, m$, 则

$$g(\lambda, \nu) \leq p^*$$

证明

对任意一个 $x \in \mathcal{D}$, 如果 x 在可行域中, 那么

$$\begin{aligned} g(\lambda, \nu) &\leq f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \\ &= f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \\ &\leq f_0(x) \end{aligned}$$

对偶问题：对偶问题

根据对偶函数, 定义对偶问题的一般形式

对偶问题

最大化: $g(\lambda, \nu)$

不等条件: $\lambda_i \geq 0, i = 1, \dots, m$

我们把对偶问题的最大值点称为 (λ^*, ν^*) , 相应的最大值称为 d^* , 这里面的对偶函数 g 定义域为 $\text{dom} g = \{(\lambda, \nu) : g(\lambda, \nu) > -\infty\}$. 在 g 的定义域中满足 $\lambda_i \geq 0$ 的那些 (λ, ν) 全体, 叫做对偶可行域. 也就是对偶问题的可行域.

对偶问题：拉格朗日对偶函数

对偶问题举例

原问题，线性规划

最小化： $c^T x$

条件： $Ax = b$, 而且 $x_i \geq 0, \forall i = 1, \dots, n$

对偶问题：拉格朗日对偶函数

对偶问题：拉格朗日对偶函数

对偶问题举例

线性规划的对偶问题

最小化: $b^T \nu$

条件: $A^T \nu - \lambda + c = 0$, 而且, $\nu_i \geq 0, \forall i = 1, \dots, n$.

对偶问题：共轭函数与拉格朗日对偶函数

当优化问题的限制条件是线性条件时，可以利用共轭函数的一些性质方便的得到对偶问题

线性约束优化问题的对偶问题

最小化: $f_0(x)$

不等条件: $AX \leq b$

等式条件: $Cx = d$

这里面向量的比较 $u < v$ 指的是 u 里边每一个分量都小于 v 里面对应的分量.

对偶问题：共轭函数与拉格朗日对偶函数

$$\begin{aligned} g(\lambda, \nu) &= \inf_x (f_0(x) + \lambda^T(Ax - b) + \nu^T(Cx - d)) \\ &= -b^T\lambda - d^T\nu + \inf_x (f_0(x) + (A^T\lambda + C^T\nu)^T x) \\ &= -b^T\lambda - d^T\nu - f_0^*(-A^T\lambda - C^T\nu) \end{aligned}$$

而这个函数的定义域就是

$$\text{dom } g = \{(\lambda, \nu) : -A^T\lambda - C^T\nu \in \text{dom } f_0^*\}.$$

对偶问题：共轭函数与拉格朗日对偶函数

最小化向量范数

对偶问题举例

最小化: $|x|$

条件: $Ax = b$

若 $f(x) = |x|$ 那么共轭函数是 $f^*(y) = 0, \forall |y| \leq 1$, 否则 $f^*(y) = +\infty$. 所以对偶问题就是:

最大化: $|-b^T \nu|$

条件: $|A^T \nu| \leq 1$

对偶问题：共轭函数与拉格朗日对偶函数

最大熵问题

对偶问题举例

$$\text{最小化: } f_0(x) = \sum_{i=1}^n x_i \ln x_i$$

$$\text{不等条件: } Ax \leq b$$

$$\text{等式条件: } \mathbf{1}^T x = 1$$

因为 $(f_1(x) + f_2(y))^* = f_1^*(w) + f_2^*(z)$, 我们有

$$f_0^*(y) = \sum_{i=1}^n e^{y_i - 1}$$

所以对偶函数为 $g(\lambda, \nu) = -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda}$

对偶问题：共轭函数与拉格朗日对偶函数

最大熵问题的对偶问题就是

最大熵问题的对偶问题

$$\text{最大化: } -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda}$$

不等条件: $\lambda \geq 0$

对偶性

根据对偶函数的性质我们已经知道在对偶可行域中, $g(\lambda, \nu)$ 总是不大于 p^* . 所以就有

弱对偶性

$$d^* \leq p^*$$

若对偶性总是对的. 相对而言的强对偶性是指一部分优化问题来说, 有更好的结论.

强对偶性

$$d^* = p^*$$

强对偶性不总成立.

强对偶性条件

第一个强对偶性的条件, 几乎所有的凸优化问题都满足强对偶性.

Slater 条件

对于一个凸优化问题

最小化: $f_0(x)$

不等条件: $f_i(x) \leq b_i, i = 1, \dots, m$

等式条件: $h_i(x) = 0, i = 1, \dots, p$

如果存在一个可行域中的点 x 使得 $f_i(x) < b_i, i = 1, \dots, m$, 那么这个凸优化问题就满足强对偶条件.

强对偶性条件

根据 Slater 条件，我们前述的几个例子都是满足强对偶性的。

满足强对偶性的例子

- 线性规划
- 最小二乘
- 最大熵问题

这种情况下我们如果发现对偶问题比原问题更容易解决，那么就可以使用对偶问题来解出 $d^* = p^*$

凸优化问题求解 (KKT)

我们来看一下如果强对偶性满足的话，这些最优化点应该满足何种条件. 这一部分中我们假定所有的函数都是可微函数.

如果 $x^*, (\lambda^*, \nu^*)$ 分别是原问题与对偶问题的最优解，那么首先这些点应该满足可行域条件

- $f_i(x^*) \leq 0$
- $h_i(x^*) = 0$
- $\lambda_i^* \geq 0$

凸优化问题求解 (KKT)

其次我们已经知道

$$\begin{aligned}d^* &= g(\lambda^*, \nu^*) \\&\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p \nu_i^* h_i(x^*) \\&= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) \\&\leq f_0(x^*) \\&= p^*\end{aligned}$$

于是 $d^* = p^*$ 意味着上述不等式全都是等式.

凸优化问题求解 (KKT)

所以我们有

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$$

, 以及

$$g(\lambda^*, \nu^*) = L(x^*, \lambda^*, \nu^*)$$

而因为

$$g(\lambda^*, \nu^*) = \inf(L(x^*, \lambda^*, \nu^*))$$

所以 x^* 是拉格朗日函数在 x 方向的驻点, 所以有

$$\nabla_x L(x^*, \lambda^*, \nu^*) = 0$$

. 综上所述我们就得到了 KKT 条件.

凸优化问题求解 (KKT)

KKT 条件

- $f_i(x^*) \leq 0, i = 1, \dots, m$
- $h_i(x^*) = 0, i = 1, \dots, p$
- $\lambda_i^* \geq 0, i = 1, \dots, m$
- $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$
- $\nabla_x L(x^*, \lambda^*, \nu^*) = 0$

其中第四个条件是由 $\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$ 以及第一个和第三个条件共同得到的.

凸优化问题求解 (KKT)

所以我们有

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$$

, 以及

$$g(\lambda^*, \nu^*) = L(x^*, \lambda^*, \nu^*)$$

而因为

$$g(\lambda^*, \nu^*) = \inf(L(x^*, \lambda^*, \nu^*))$$

所以 x^* 是拉格朗日函数在 x 方向的驻点, 所以有

$$\nabla_x L(x^*, \lambda^*, \nu^*) = 0$$

. 综上所述我们就得到了 KKT 条件.

凸优化问题求解 (KKT)

KKT 条件叙述

- $f_i(x^*) \leq 0, i = 1, \dots, m$
- $h_i(x^*) = 0, i = 1, \dots, p$
- $\lambda_i^* \geq 0, i = 1, \dots, m$
- $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$
- $\nabla_x L(x^*, \lambda^*, \nu^*) = 0$

其中第四个条件是由 $\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$ 以及第一个和第三个条件共同得到的.

凸优化问题求解 (KKT)

KKT 条件使用

- 对于凸优化问题, KKT 条件是 $x^*, (\lambda^*, \nu^*)$ 分别作为原问题和对偶问题的最优解的充分必要条件.
- 对于非凸优化问题, KKT 条件仅仅是必要而非充分.

凸优化问题求解 (KKT)

使用 KKT 条件解决优化问题例子

$$\begin{aligned} \text{最小化: } & (1/2)x^P x + q^T x + r \\ \text{等式条件: } & Ax = b \end{aligned}$$

KKT 条件是

$$Ax^* = b$$

以及

$$Px^* + q + A^T v^* = 0$$

我们求解这个线性方程即可得到索要的结果.

应用举例：支持向量机最简单形式

支持向量机的最简单形式

空间 \mathbb{R}^n 中有可分的两个点集 C, D . 我们希望找到一个最合适的超平面 $a^T x = b$ 对他们进行区分. 也就是说对于 $p \in C, q \in D$, 有

$$a^T p > b, \quad a^T q < b$$

也就是说存在一个正数 t 使得

$$a^T p - b \geq t, \quad a^T q - b \leq -t$$

这个正数 t 一定程度上描述了两个集合被分开的程度.

为了体现“最合适”，一个比较好的想法就是希望当 a 是单位向量的时候， t 越大越好. 于是的到了一个优化问题

应用举例：支持向量机最简单形式

SVM 优化问题

最小化: $-t$

不等条件 1: $-a^T p_i + b \leq -t$

不等条件 2: $a^T q_i - b \leq -t$

不等条件 3: $-t \leq 0$

等式条件: $|a|^2 = 1$

但是这里面 $|a|^2 = 1$ 并非凸条件，所以我们把它换成 $|a|^2 \leq 1$ 。
就得到一个跟原问题等价的凸优化问题。

应用举例：支持向量机最简单形式

SVM 凸优化问题

最小化: $-t$

不等条件 1: $-a^T p_i + b \leq -t$

不等条件 2: $a^T q_i - b \leq -t$

不等条件 3: $-t \leq 0$

不等条件 4: $|a|^2 \leq 1$

具体求解，因为这是一个凸优化问题，所以可以选择使用 KKT 条件来解方程求解。

线性代数：参考资料

参考资料

- 非常清晰完整的经典教材：凸优化，Stephen Boyd, Lieven Vandenberghe

作业

- 教材：凸优化 (英文版页码与题号) p60:2.32,10,2.12,2.16,2.23,2.26;
p113:3.1,3.2,3.12,3.21,3.36,3.39; p189:4.2,4.8,4.10,4.21
p273:5.1,5.4,5.11,5.22,5.24

谢谢大家!