大数据下的广告排序技术及实践

蒋龙

2013年11月16日

提纲

- 广告排序的核心问题
  - 点击率预估
- 基于机器学习的点击率预估
  - 数据，特征，模型，评测
  - 大数据下的特征处理和模型训练
- 深入讨论

搜索推广

Query：雪纺连衣裙

定向推广

热卖单品　精品凉鞋　热卖女鞋　新款凉鞋　坡跟女凉鞋　休闲凉拖　女鞋凉鞋　美鞋　拖鞋　性感鱼嘴　舒适单鞋　更多热卖

疯抢!漫步云端 女士包臀收腰蕾丝花边连衣裙

￥598.00

Amovo纯可可脂巧克力8口味礼盒 零食 包邮

￥109.00

思加图 专柜正品 2012夏季新款拖鞋凉拖凉鞋

￥238.00

0利润大牌高档退换包邮真丝连衣裙送彩票

￥800.00

您可能对这些宝贝感兴趣

广告展现流程

1. 候选广告选取
   - 用户 -> Query <-> Bidwords <- 广告主
2. 广告排序
   - 按ECPM(Effective cost per mille)排序
     - ECPM=CTR*Bid
   - 广告平台受益最大，兼顾用户和广告主需求
3. 扣费
   - GSP拍卖(Generalized Second Price Auction)机制
   - $CPC_i = (CTR_{i+1} * CPC_{i+1})/CTR_i$

核心问题：点击率

- 广告排序
  - ECPM=CTR*Bid
  - 排序时Bid已知，但CTR未知
- 扣费
  - $CPC_i = (CTR_{i+1} * CPC_{i+1})/CTR_i$
  - 当前广告的扣费依赖当前及后一条广告的CTR
- 所以，计算每条广告的CTR是排序和扣费的核心
  - P(click|query, ad)

直接估计

- 广告每次被展现后有两种可能的结果：点击和不点击；
  - 假设点击概率为p，则不点击概率为1-p
- 假设p恒定，则广告在n次展现中被点击的次数X服从二项分布。被点击k次的概率为

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k}=b(k;n,p)$$

$$(k=0,1,\cdots,n),$$

- 基于历史统计的点击率估计
  - 例如，给定query时，某广告被n次展现k次点击，根据最大似然估计
  - ctr = k/n

直接估计的不足

- 直接估计的不足
  - 数据稀疏
    - 1千万广告，1千万query->100万亿pair
    - 新query，新广告
  - 真实点击率低，需要大量展现数据才能得到可靠估计
    - An ad with a true CTR of 5% must be shown 1000 times before we are even 85% confident that our estimate is within 1% of the true CTR
    - 大量尝试性展现浪费流量价值
  - 点击率未必恒定
- 解决方案：利用广告和query的各种特征，通过机器学习模型来预测

基于机器学习的点击率预估

- 问题类型
  - 分类：点击or不点击，但需要点击的概率
  - 回归：直接拟合点击率
- 模型和算法应尽量简单，易于并行化
  - 海量数据
    - 训练数据，特征
  - 快速更新需求
- 常用方法
  - 逻辑回归
  - Boosting类，如GBRT

逻辑回归模型

- 二元逻辑回归(Logistic Regression, LR)模型

$$P(y=1|x)=\frac{1}{1+e^{-(\beta_0+\sum\beta_i*x_i)}} \qquad P(y=0|x)=\frac{e^{-(\beta_0+\sum\beta_i*x_i)}}{1+e^{-(\beta_0+\sum\beta_i*x_i)}}$$

- 几率(odds)

$$\frac{p(y=1)}{p(y=0)}=e^{(\beta_0+\sum\beta_i*x_i)}$$

- 对数形式

$$\ln(\frac{p(y=1)}{p(y=0)})=\beta_0+\sum\beta_i*x_i$$

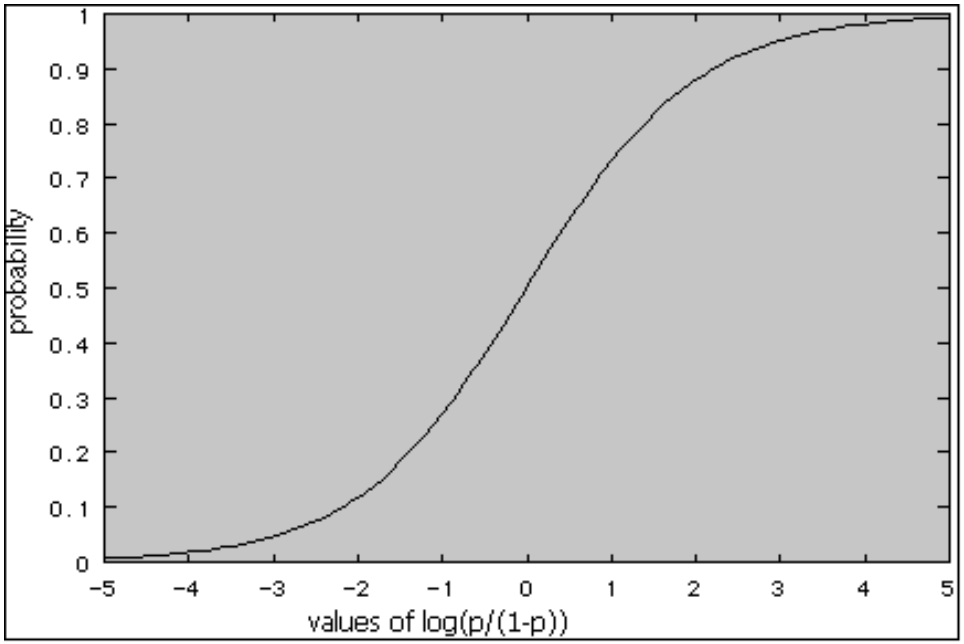

基于LR的点击率预测

- 基于LR的点击模型

$$P(y=1|x)=\frac{1}{1+e^{-(\beta_0+\sum\beta_i*x_i)}}$$

  - Where, x代表一个(query, ad)对应的特征向量, y属于{1,0}分别代表点击和不点击，p(y=1|x)就代表给定query下，某ad的点击率

点击率预测特征

- 广告创意特征
  - 图片，标题文字，价格，销量
  - 推广商品所属类目，包含属性
  - 创意组，推广计划，广告主
- Query信息
  - 包含的Terms
  - Query分析：类目，属性
  - Query扩展：同义词，相似query
- 环境特征
  - 用户，时间

点击率预测特征

- 名义特征
  - 时间，创意ID等
- 点击反馈特征
  - 计算历史上包含该特征的(query, ad)的点击率
  - E.g., ad所属广告计划的历史点击率
- 组合特征
  - E.g., query与ad标题匹配的term个数

模型训练

- 训练/测试数据
  - 一定时间内的广告系统日志
    - (query, ad): click, pv-click
  - E.g., 1个月数据训练，接下来的1天数据测试
- 训练目标：最小化负对数似然
  - 似然函数：$\prod_l P(Y^l \mid X^l, \beta)$
  - 负对数似然：

$$l(\beta) = -\sum_l \log p(Y^l \mid X^l, \beta)$$

$$= -\sum_l [L_l^+ \log P(Y^l = 1 \mid X^l, \beta) + L_l^- \log P(Y^l = 0 \mid X^l, \beta)]$$

正则化

- 通过加上正则项，得到稀疏模型

$$\min_{\beta} -\sum_{l}[L_l^+ \log P(Y^l = 1 \mid X^l, \beta) + L_l^- \log P(Y^l = 0 \mid X^l, \beta)] + \lambda \sum_{i} |\beta_i|$$

  - 通过正则项控制模型复杂度，避免over-fitting
  - L1正则项能使大量的无效特征权重为0，起到特征选择作用

模型训练

- 参数估计算法
  - 梯度下降
  - 牛顿法
  - BFGS
- L-BFGS
  - 拟牛顿法的一种，利用有限内存近似BFGS算法
  - 利用历史值和梯度寻找当前方向(Two loop)
  - Line search确定步长

效果评估

- 离线自动评估
  - 在测试数据上，评测模型的AUC，MSE指标
- 离线人工评估
  - 通过随机选取的query集合来对比新旧版本的相关性效果
- 线上评估
  - 把模型部署到线上，分配一部分真实流量来评估模型效果(CTR, ECPM)

AUC指标

- Receiver Operating Characteristics (ROC) graph

Hypothesized class \ True class	p	n
Y	True Positives	False Positives
N	False Negatives	True Negatives

$$\text{fp rate} = \frac{FP}{N} \qquad \text{tp rate} = \frac{TP}{P}$$

$$\text{precision} = \frac{TP}{TP+FP} \qquad \text{recall} = \frac{TP}{P}$$

$$\text{accuracy} = \frac{TP+TN}{P+N}$$

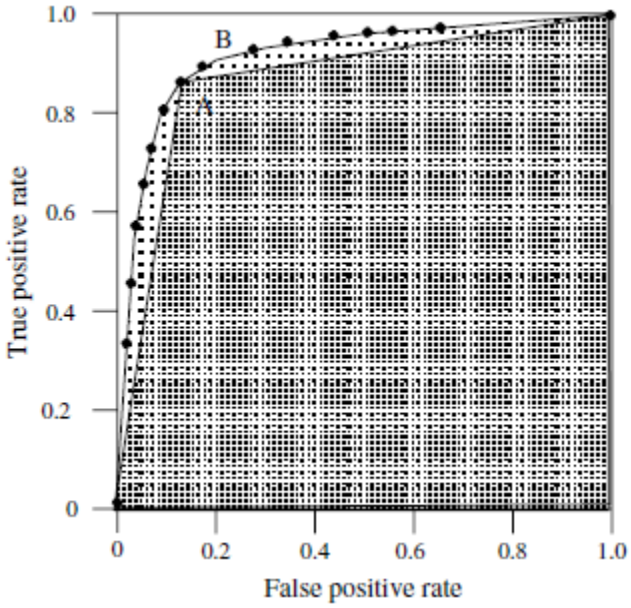

- Area under an ROC curve (AUC)
  - FPRate-TPRate曲线下方的面积
  - 衡量了排序的准确性
  - 越接近1模型越好，0.5是随机模型

大数据下的点击率预测

- 大数据挑战
  - 海量特征
  - 海量训练样例
  - 模型快速更新，多模型试验
- 解决方案
  - 数据/特征处理
    - 基于Hadoop的并行数据处理
  - 模型训练
    - 基于MPI的并行训练算法

大规模机器学习平台

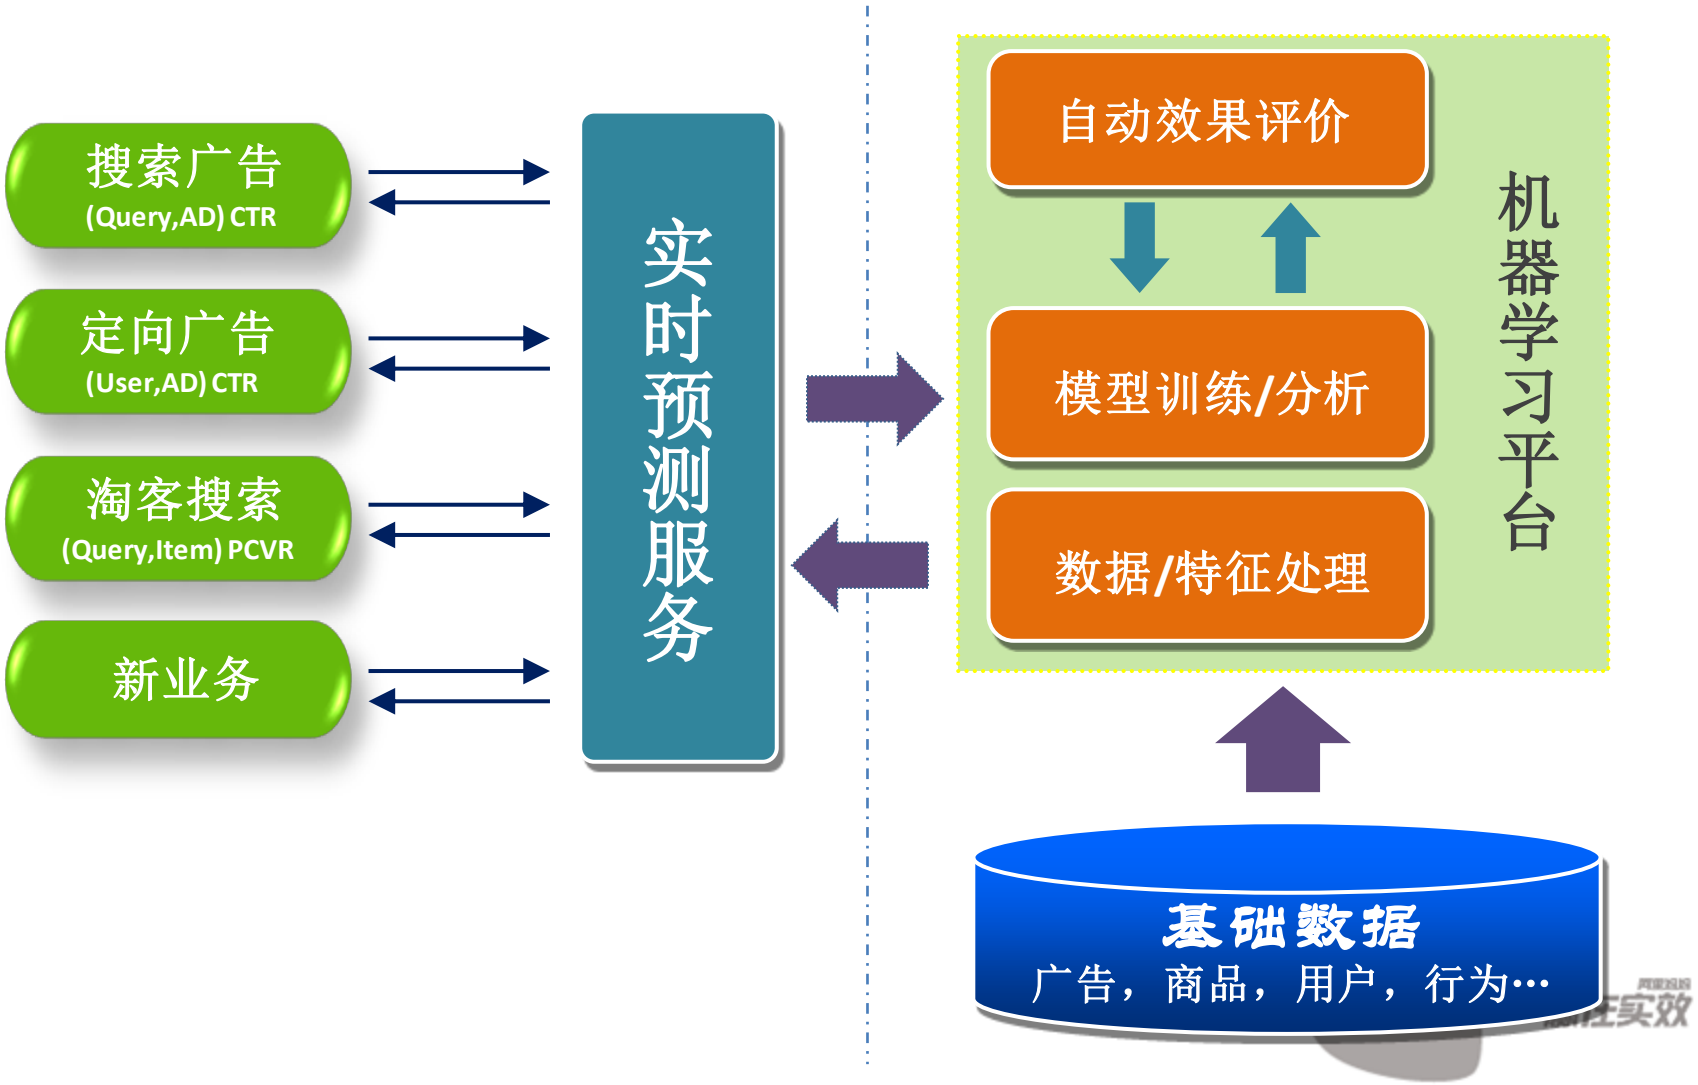
搜索广告
(Query,AD) CTR
定向广告
(User,AD) CTR
淘客搜索
(Query,Item) PCVR
新业务
实时预测服务
自动效果评价
模型训练/分析
数据/特征处理
机器学习平台
基础数据
广告，商品，用户，行为…

大数据处理平台

- 大规模MapReduce+HDFS集群
  - 4000+节点，80PB+存储
  - 搜索广告点击率预估
    - 原始日志分析：10T+
    - 特征提取：吞吐50T
    - 训练数据：20T
- 基于MPI的机器学习算法平台
  - 500+台机器（单机24 CPUs, 96G内存）
  - 自动任务调度和监控系统，部署多种算法，如LR，PLSA，LDA，SVM，GBDT等
  - 搜索广告点击率预估
    - 十亿级特征，百亿级训练样例
    - 运算时间：~2小时

MPI与Map-Reduce

- MPI(**M**essage **P**assing **I**nterface)：消息传递接口
  - 消息传递函数库的标准规范
  - 通过在进程间传递消息完成数据交换，如Send, Recv
  - 程序员可以深入控制数据交互
- MPI VS. Map-Reduce模型
  - MPI：适合逻辑复杂的迭代运算，如机器学习算法
  - MR：适合计算独立，迭代少的任务

基于MPI的并行LR训练

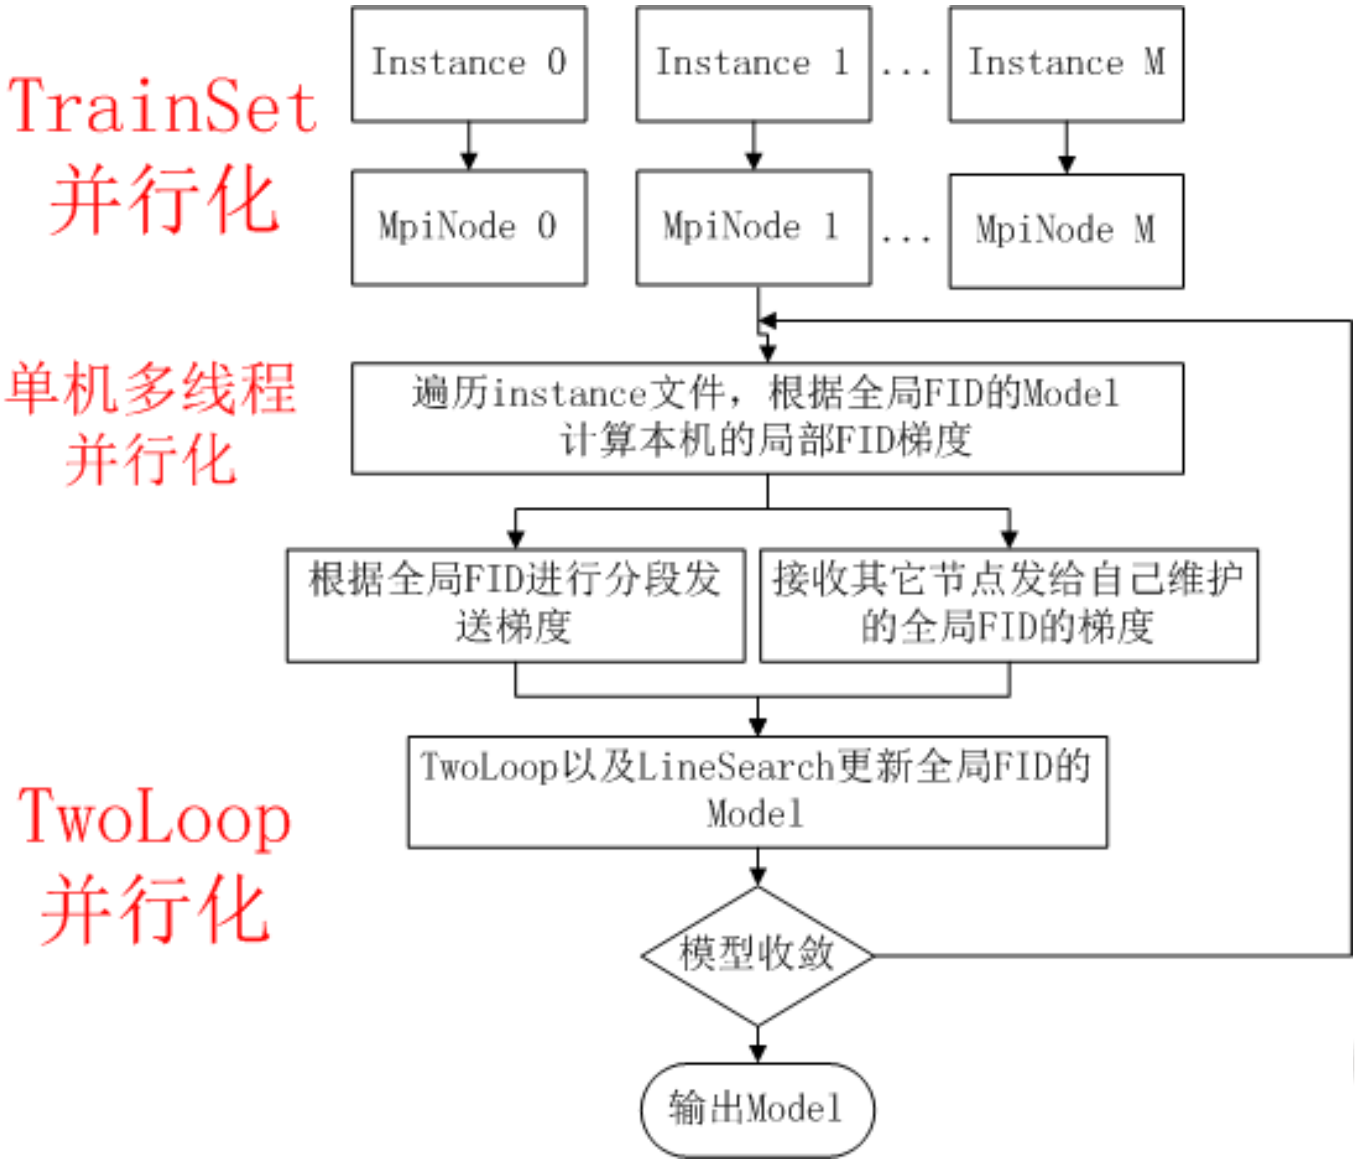

深入讨论-位置偏差

- 位置偏差(position bias)
  - 假设：不同位置上的广告被用户看到的概率不同，排位靠前的广告被看到的概率更大，导致其点击率“天然”更高一些
- 解决方案一：
  - (Cheng and Cantú-Paz, 2010)
    - 计算广告CTR时用不同排位上的平均ctr进行调整

$$\mathrm{COEC} = \frac{\sum_{r=1}^{R} c_r}{\sum_{r=1}^{R} i_r * CTR_r}$$

深入讨论-位置偏差

- 解决方案二：
  - Online Learning from Click Data for Sponsored Search. (Ciaramita et al., 2008)
    - 只有当排位低的广告被点击而排位高的广告没有被点击时，才使用这些广告作为训练数据

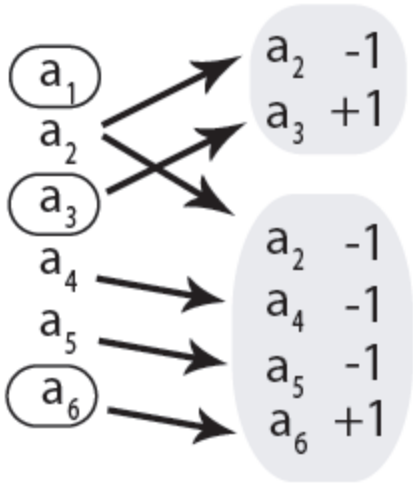

深入讨论-个性化

- Personalized Click Prediction in Sponsored Search.
  - Haibin Cheng, Erick Cantú-Paz. WSDM. 2010.
- 假设：query相同时，不同user对不同ad的点击率也相差较大
- 解决方案：加入user特征到LR模型里，预估p(c|q,a,u)
  - Demographic特征
    - 如年龄，性别，婚姻状况，职业，兴趣等
  - User-specific特征
    - 如用户历史CTR，user组合特征(User-Ad, User-Query)

深入讨论-广告间相互影响

- Relational Click Prediction for Sponsored Search
  - Chenyan Xiong, Taifeng Wang, Wenkui Ding, Yidong Shen, Tie-Yan Liu. WSDM 2012.
- 假设：某条广告的点击率会受到同时展现的其他广告的影响
- 解决方案：同时预估所有广告的点击率，考虑广告间的相互影响
  - 广告间的相似度
  - Continuous CRF model with MLE

$$P(Y|X) = \frac{1}{Z(X)} \exp\left\{\sum_i h(y_i, X; w) + \sum_{j>i} \beta g(y_i, y_j, X)\right\}$$

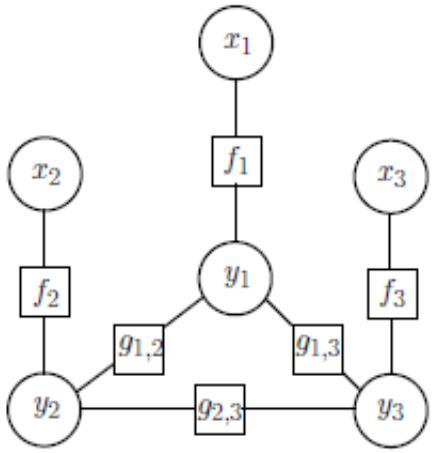

Thanks!