

线性代数进阶

邓明格

七月在线

mingge_deng@brown.edu

March 31, 2017

主要内容

- ① 重要的特殊矩阵
- ② 矩阵变换
 - 相似变换
 - 相合变换
 - 正交相似变换
- ③ 矩阵分解
- ④ PCA 理论及实例
 - 低阶矩阵近似
 - PCA 应用

对称方阵

对称方阵

- 定义: $\mathbf{H} \in \mathcal{R}^{n,n}$, $h_{ij} = h_{ji}$ or $\mathbf{H}^T = \mathbf{H}$ 。
- 协方差矩阵: $\mathbf{H} = (\mathbf{X} - \mathbf{X}_0)(\mathbf{X} - \mathbf{X}_0)^T$, \mathbf{X} 为列向量或者 $n \times n$ 方阵。
- 海森矩阵 (牛顿法):

$$\mathbf{H}(f(\beta)) = \begin{bmatrix} \frac{\partial^2 f}{\partial \beta_1 \partial \beta_2} & \cdots & \frac{\partial^2 f}{\partial \beta_1 \partial \beta_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial \beta_n \partial \beta_1} & \cdots & \frac{\partial^2 f}{\partial \beta_n \partial \beta_n} \end{bmatrix} \quad (1)$$

- 内积矩阵

正定方阵

正定方阵

- 定义: $\mathbf{H} \in \mathcal{R}^{n,n}$ 为对称方阵, $\forall \mathbf{x} \neq \mathbf{0}$, 满足 $\mathbf{x}^T \mathbf{H} \mathbf{x} > 0$, 则 \mathbf{H} 为正定方阵, < 0 为负定, ≥ 0 为半正定方阵。
- 协方差矩阵
- 海森矩阵 (如果 $f(\beta)$ 为凸函数)
- 内积矩阵

其他特殊矩阵

- 正交矩阵 $\mathbf{H} \in \mathcal{R}^{n,n}, \mathbf{H}^T \mathbf{H} = \mathbf{H} \mathbf{H}^T = \mathbf{I}$ 。
- 三角矩阵
- 对角矩阵
- 稀疏矩阵

相似变换

相似变换

- 定义：如果方阵 \mathbf{A} 与 $\tilde{\mathbf{A}}$ 满足 $\tilde{\mathbf{A}} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ ，那么方阵 \mathbf{A} 与 $\tilde{\mathbf{A}}$ 互为相似矩阵。
- 几何意义：同一个线性变换在不同的基下的表达形式。
- 线性空间 \mathbf{V} 可以由基 α 或者基 $\tilde{\alpha}$ 来描述。两组基满足 $\tilde{\alpha} = \alpha \cdot \mathbf{P}$ ，那么同一个向量在不同基下的坐标满足 $\tilde{\mathbf{x}} = \mathbf{P}^{-1}\mathbf{x}$ 。
- 线性变换 $\mathbf{T} : \mathbf{V} \rightarrow \mathbf{V}$ ：
 - 线性空间 \mathbf{V} 由基 α 描述，线性变换可以表示为 $\mathbf{x} = \mathbf{A}\mathbf{y}$
 - 线性空间 \mathbf{V} 由基 $\tilde{\alpha}$ 描述，线性变换可以表示为 $\tilde{\mathbf{x}} = \tilde{\mathbf{A}}\tilde{\mathbf{y}}$

$$\mathbf{P}^{-1}\mathbf{x} = \tilde{\mathbf{A}}\mathbf{P}^{-1}\mathbf{y} \implies \mathbf{x} = \mathbf{P}\tilde{\mathbf{A}}\mathbf{P}^{-1}\mathbf{y} \implies \mathbf{A} = \mathbf{P}\tilde{\mathbf{A}}\mathbf{P}^{-1} \quad (2)$$

相似变换实例

线性变换 $\mathbf{T} : \mathcal{R}^2 \rightarrow \mathcal{R}^2$, 沿 $y = x$ 方向拉伸 2 倍

- 选择基 $\alpha_1 = (1, 0), \alpha_2 = (0, 1)$ 描述, $\mathbf{A} = \begin{bmatrix} 3/2 & 1/2 \\ 1/2 & 3/2 \end{bmatrix}$
- 选择基 $\alpha_1 = (1, 1), \alpha_2 = (1, -1)$ 描述, $\tilde{\mathbf{A}} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$

相似变换不变量：行列式

\mathbf{A} 与 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ 描述同一个线性变换，体积变化率不变

$$\begin{aligned}\det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{P}) \det(\mathbf{A}) \\ &= \det(\mathbf{A})\end{aligned}\tag{3}$$

提示: $\det(\mathbf{AB}) = \det(\mathbf{BA}) = \det(\mathbf{A}) \det(\mathbf{B})$

相似变换不变量：迹

迹

- 定义：迹是矩阵所有对角元的和： $tr(\mathbf{A}) = \sum_i a_{ii}$
- 迹是矩阵特征值的总和。（作业，提示：特征多项式韦达定理）
- $tr(\mathbf{AB}) = tr(\mathbf{BA})$ 。（作业，提示：定义）
- 几何意义： $\exp(tr(\mathbf{A}))$ 是线性变换 $\exp(\mathbf{A})$ 的体积变化率）。

$$\exp(tr(\mathbf{A})) = \det(\exp(\mathbf{A})) \quad (4)$$

$$e^{\mathbf{A}} = \mathbf{I} + \mathbf{A} + \mathbf{A}^2/2 + \dots \quad (5)$$

$\exp(\mathbf{A})$ 与 $\exp(\mathbf{P}^{-1}\mathbf{A}\mathbf{P})$ 描述同一个线性变换，体积变化率不变

$$tr(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) = tr(\mathbf{APP}^{-1}) = tr(\mathbf{A} \cdot \mathbf{I}) = tr(\mathbf{A}) \quad (6)$$

相似变换不变量：特征值

特征值

特征值是特征方程 $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$ 的根，如果 $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$ ，那么 $\det(\mathbf{P}^{-1}(\mathbf{A} - \lambda\mathbf{I})\mathbf{P}) = 0$ ，于是 $\det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P} - \lambda\mathbf{I}) = 0$

注意：特征值是最重要的相似不变量，利用这个相似不变量可以得出其他的不变量。

内积

内积

\mathbf{V} 是线性空间, 内积用来表达线性空间的空间度量, 是正定、对称以及双线性形式, $\langle \cdot, \cdot \rangle : \mathbf{V} \times \mathbf{V} \rightarrow \mathcal{R}$

- $G(\mathbf{x}, \mathbf{x}) \geq 0 \quad G(\mathbf{x}, \mathbf{x}) = 0 \quad \text{iff} \quad \mathbf{x} = 0,$
- $G(\mathbf{x}, \mathbf{y}) = G(\mathbf{y}, \mathbf{x})$
- $G(\mathbf{x} + \mathbf{y}, \mathbf{z}) = G(\mathbf{x}, \mathbf{z}) + G(\mathbf{y}, \mathbf{z})$
- 欧氏空间标准内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \sum_{k=1}^n \mathbf{x}_k \mathbf{y}_k$

如果 $\alpha\{\alpha_1, \dots, \alpha_k\}$ 是空间 \mathbf{V} 的一组基, 内积一般可以用一个对称矩阵 H_α 来表示

$$h_{ij} = G(\alpha_i, \alpha_j) = G(\alpha_j, \alpha_i) = h_{ji} \quad (7)$$

任意两个向量 $\mathbf{v} = \alpha \cdot \mathbf{x}$, $\mathbf{w} = \alpha \cdot \mathbf{y}$, 其中 \mathbf{x}, \mathbf{y} 为基 α 下的坐标, 那么

$$G(\mathbf{v}, \mathbf{w}) = \mathbf{x}^T H_\alpha \mathbf{y} \quad (8)$$

相合变换

- 如果两个对称方阵 \mathbf{A} 与 $\tilde{\mathbf{A}}$ 满足 $\tilde{\mathbf{A}} = \mathbf{P}^T \mathbf{A} \mathbf{P}$. 那么这两个方阵就互为相合矩阵。
- 相似矩阵的几何意义是同一个内积结构在不同基下的表示形式。

线性空间 \mathbf{V} 可以由基 α 或者基 $\tilde{\alpha}$ 来描述。两组基满足 $\alpha = \tilde{\alpha} \cdot \mathbf{P}$, 那么任意一向量 $\mathbf{v} = \alpha \cdot \mathbf{x} = \tilde{\alpha} \mathbf{P} \cdot \mathbf{x} = \tilde{\alpha} \cdot \tilde{\mathbf{x}}$ 。

$$\begin{aligned} G(\mathbf{v}, \mathbf{w}) &= \mathbf{x}^T \mathbf{H}_\alpha \mathbf{y} = \tilde{\mathbf{x}}^T \tilde{\mathbf{H}}_\alpha \tilde{\mathbf{y}} = \mathbf{x}^T \mathbf{P}^T \tilde{\mathbf{H}}_\alpha \mathbf{P} \mathbf{y} \\ &\implies \mathbf{H} = \mathbf{P}^T \tilde{\mathbf{H}} \mathbf{P} \end{aligned} \tag{9}$$

相合变换不变量

相合变换不变量

- 矩阵的正定性（正定，负定）
- 矩阵的正负特征值的个数（Signature）
- 相合变换下矩阵保持对称性

正交相似变换

正交相似变换

- 正交相似变换同时满足相似与相合变换的条件，也就是说它同时保持了矩阵的相似与相合不变量。
- 如果两个对称方阵 \mathbf{A} 与 $\tilde{\mathbf{A}}$ 满足 $\tilde{\mathbf{A}} = \mathbf{P}^T \mathbf{A} \mathbf{P}$ ，且 \mathbf{P} 是正交矩阵 $\mathbf{P}^T = \mathbf{P}^{-1}$ 。那么 \mathbf{A} 与 $\tilde{\mathbf{A}}$ 就互为正交相似。

任何一个对称矩阵 \mathbf{A} 都可以正交相似于一个对角矩阵 \mathbf{D} ，或者说总存在一个正交矩阵 \mathbf{P} ，使得 $\mathbf{A} = \mathbf{P}^T \mathbf{D} \mathbf{P}$ ，且对角矩阵 \mathbf{D} 由 \mathbf{A} 的特征值构成。

正交相似实例及几何意义

对称方阵 $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, 求及正交相似标准型:

- 求特征值 $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$, 得到 $\lambda_1 = 1, \lambda_2 = 3$ 。
- 求特征向量 $\mathbf{A}\mathbf{v}_i = \lambda_i\mathbf{v}_i$, 得到 $\mathbf{v}_1^T = (1/\sqrt{2}, 1/\sqrt{2})$, $\mathbf{v}_2^T = (-1/\sqrt{2}, 1/\sqrt{2})$ 。
- $\mathbf{A} = \mathbf{P}^T\mathbf{D}\mathbf{P}$, $\mathbf{D} = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}$, $\mathbf{P} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$

几何意义: 方阵 \mathbf{A} 对应的线性变换: 在 \mathbf{v}_1 方向放大三倍, \mathbf{v}_2 方向保持不变。

LU 分解与 cholesky 分解

LU 分解

- 定义: $\mathbf{A} \in \mathcal{R}^{n \times n}$, 存在唯一的单位下三角矩阵 \mathbf{L} 和非奇异上三角矩阵 \mathbf{U} , 使得 $\mathbf{A} = \mathbf{LU}$, 充要条件是 \mathbf{A} 的所有顺序主子矩阵 $\mathbf{A}_k = \mathbf{A}(1:k, 1:k)$ 都非奇异。
- 方法: 高斯消去法 ($\mathcal{O}(n^3)$), (如何求解线性方程组)

cholesky 分解

- 定义: $\mathbf{A} \in \mathcal{R}^{n \times n}$ 对称正定, 则存在唯一的对角线元素为正的下三角矩阵 \mathbf{L} , 使得 $\mathbf{A} = \mathbf{LL}^T$ 。
- 联系正交相似标准型: $\mathbf{A} = \mathbf{P}^T \mathbf{D} \mathbf{P}$, 如果 \mathbf{A} 对称正定, 特征值都为正数, 所以 $\mathbf{L} = \mathbf{P}^T \mathbf{D}^{1/2} \mathbf{P}$ 。

QR 分解

- 定义: $\mathbf{A} \in \mathcal{R}^{n \times n}$, 可以被分解为 $\mathbf{A} = \mathbf{QR}$, 其中 \mathbf{Q} 是正交矩阵, 而 \mathbf{R} 是上三角矩阵。如果 \mathbf{A} , 分解唯一。
- Gram-Schmidt 正交化.

$$\begin{aligned}\beta_1 &= \mathbf{v}_1, & \eta_1 &= \frac{\beta_1}{\|\beta_1\|} \\ \beta_2 &= \mathbf{v}_2 - \langle \mathbf{v}_2, \eta_1 \rangle \eta_1, & \eta_2 &= \frac{\beta_2}{\|\beta_2\|} \\ \beta_3 &= \mathbf{v}_3 - \langle \mathbf{v}_3, \eta_1 \rangle \eta_1 - \langle \mathbf{v}_3, \eta_2 \rangle \eta_2, & \eta_3 &= \frac{\beta_3}{\|\beta_3\|} \\ &\vdots & &\vdots \\ \beta_n &= \mathbf{v}_n - \sum_{i=1}^{n-1} \langle \mathbf{v}_n, \eta_i \rangle \eta_i, & \eta_n &= \frac{\beta_n}{\|\beta_n\|}\end{aligned}$$

这样就得到 $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 上的一组正交基 $\{\beta_1, \dots, \beta_n\}$, 以及相应的标准正交基 $\{\eta_1, \dots, \eta_n\}$

SVD 分解

SVD 分解

- 定义：对于任何一个矩阵 $\mathbf{A} \in \mathcal{R}^{m \times n}$ ，存在正交矩阵 $\mathbf{U}^{m \times m}, \mathbf{V}^{n \times n}$ ，使得 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ ，其中 $\mathbf{\Sigma}^{m \times n}$ 是一个对角矩阵，且

$$\mathbf{\Sigma} = \begin{bmatrix} \tilde{\mathbf{\Sigma}} & \mathbf{0}_{r, n-r} \\ \mathbf{0}_{m-r, r} & \mathbf{0}_{m-r, n-r} \end{bmatrix}, \quad \tilde{\mathbf{\Sigma}} = \text{diag}(\sigma_1, \dots, \sigma_r) \quad (10)$$

Diagram illustrating the SVD decomposition $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$. The matrices are represented by colored boxes with their dimensions written below them:

- \mathbf{A} (blue box) is $m \times n$.
- \mathbf{U} (green box) is $m \times m$.
- $\mathbf{\Sigma}$ (blue box) is $m \times n$.
- \mathbf{V}^T (orange box) is $n \times n$.

SVD 分解与特征值的联系：(作业)


- $\mathbf{U}^{m \times m}$ 为 $\mathbf{A}\mathbf{A}^T$ 的特征向量。
- $\mathbf{V}^{n \times n}$ 为 $\mathbf{A}^T\mathbf{A}$ 的特征向量。
- $\tilde{\Sigma}$ 为 $\mathbf{A}\mathbf{A}^T$ 或者 $\mathbf{A}^T\mathbf{A}$ 的非零特征值的平方根，称为奇异值。

伪逆的 SVD 表达：(作业)



低阶矩阵近似

部分奇异值分解: 用少部分大的奇异值来近似描述矩阵

$$\mathbf{A} \approx \mathbf{U}_{m,k} \Sigma_{k,k} \mathbf{V}_{k,n}^T \quad (11)$$



低阶矩阵近似实例



$k = 9$ 包含 96% 图片的方差。

低阶矩阵近似

对于任何一个矩阵 $\mathbf{A} \in \mathcal{R}^{m \times n}$, 并且 $r = \text{rank}(\mathbf{A}) > 0$, 如何用低阶的矩阵近似

$$\begin{aligned} \min_{\mathbf{A}_k \in \mathcal{R}^{m \times n}} & \|\mathbf{A} - \mathbf{A}_k\|_F^2 \\ \text{s.t. : } & \text{rank}(\mathbf{A}_k) = k < r \end{aligned} \quad (12)$$

最优解:

$$\begin{aligned} \mathbf{A} &= \mathbf{U}\Sigma\mathbf{V}^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \\ \implies \mathbf{A}_k &= \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T \end{aligned} \quad (13)$$

PCA

PCA: 最常用的线性降维方法，它的目标是通过某种线性投影，将高维的数据映射到低维的空间中表示，并期望在所投影的维度上数据的方差最大。

- 数据点: $\mathbf{x}_i \in \mathcal{R}^n, i = 1, \dots, m$, 归一化, 使中心为零, 并且方差为 1。
- 寻找空间中的一个方向 $\mathbf{z} \in \mathcal{R}^n, \|\mathbf{z}\|_2 = 1$, 使得所有数据在 \mathbf{z} 上的投影方差和最大 (保持最多信息)。
- 数据点在 \mathbf{z} 方向上的投影为 $\alpha_i = \mathbf{x}_i^T \mathbf{z}$
- 数据投影方差和: $\sum_{i=1}^m \alpha_i^2 = \sum_{i=1}^m \mathbf{z}^T \mathbf{x}_i \mathbf{x}_i^T \mathbf{z}$

PCA 问题:

$$\max_{\mathbf{z} \in \mathcal{R}^n} \mathbf{z}^T (\mathbf{X}\mathbf{X}^T) \mathbf{z} \quad \text{s.t.} \quad \|\mathbf{z}\|_2 = 1 \quad (14)$$

由 SVD 求解 PCA 问题 (作业)

我们可以得到 $\mathbf{z} = \mathbf{u}_1$, 方差和为 σ_1^2 。

推荐问题 PCA 分析

谢谢大家!!

下节课主要内容:

- 微积分回顾
- 牛顿法
- 概率论回顾
- 极大似然估计