

# 矩阵论与凸优化第 4 课凸优化初步

管老师

七月在线

Apr, 2017

# 主要内容

- 优化与凸优化简介
  - 优化问题基本形式
  - 凸优化问题基本形式
  - 凸优化的应用
- 凸集合与凸函数基本概念
  - 凸集合与凸函数的关系
  - 凸集合与凸函数的性质对应
- 凸优化问题举例
  - 混合高斯模型和 EM 算法简介

- 本节课常用数学记号

$V, W$  向量空间

$v, w$  向量

$\mathbb{R}^n, \mathbb{R}^m$  实坐标空间

$\alpha, \beta$   $V$  和  $W$  的基

$T: V \rightarrow W$  向量空间  $V$  到  $W$  的线性映射

$A_{\alpha, \beta}(T)$  线性映射  $T$  在  $\alpha$  和  $\beta$  这两组基下的矩阵

$G(v_1, v_2)$  内积空间  $V$  上的内积

$H_\alpha$   $G$  在基  $\alpha$  下的矩阵形式

# 优化与凸优化简介

## 优化问题

### 优化问题的一般形式

最小化:  $f_0(x)$

条件:  $f_i(x) \leq b_i, i = 1, \dots, m.$

其中  $f_0(x)$  为目标函数, 条件里的不等式是限制条件.

# 优化与凸优化简介

举例:

$$Ax=b$$

## 极大似然估计

如果  $L(\mu, \sigma)$  是一个极大似然估计问题中的似然函数, 其中  $\mu, \sigma$  分别是期望和方差, 那么极大似然估计的问题转化为

$$\text{最小化: } -L(\mu, \sigma)$$

$$\text{条件: } \sigma \geq 0$$

## 最小二乘

如果  $A_{n \times k}$  是一个矩阵,  $b \in \mathbb{R}^n$  是一个向量, 对于  $x \in \mathbb{R}^k$

$$\text{最小化: } f_0(x) = \|Ax - b\|^2$$

# 优化与凸优化简介

## 凸优化问题

### 凸优化问题的一般形式

最小化:  $f_0(x)$

条件:  $f_i(x) \leq b_i, i = 1, \dots, m.$

其中  $f_0(x)$  为目标函数, 条件里的不等式是限制条件.

- 凸优化问题的条件,  $f_0, f_1, \dots, f_m$  都是凸函数.
- 凸优化问题的特点, 局部最优等价于全局最优.
- 凸优化问题的求解, 几乎总有现成的工具来求解.



# 优化与凸优化简介

## 凸优化的应用

- 凸优化问题逼近非凸优化问题，寻找非凸问题的初始点
- 利用对偶问题的凸性给原问题提供下界估计
- 凸优化问题可以给非凸问题带来一些启发

$$\begin{aligned} & \|Ax - b\|^2 + \|x\|_1 \\ & \|Ax - b\|^2 + \lambda \|x\|_1 \end{aligned}$$

# 凸集合与凸函数

## 凸集合定义

如果一个集合  $\Omega$  中任何两个点之间的线段上任何一个点还属于  $\Omega$ , 那么  $\Omega$  就是一个凸集合.i.e.

$$\lambda x_1 + (1 - \lambda)x_2 \in \Omega, \forall x_1, x_2 \in \Omega, \lambda \in (0, 1)$$

## 凸函数定义

如果一个函数  $f$  定义域  $\Omega$  是凸集, 而且对于任何两点. 以及两点之间线段上任意一个点都有

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

$$\forall x_1, x_2 \in \Omega, \lambda \in (0, 1)$$



# 凸集合与凸函数



# 凸集合与凸函数

## 函数的上境图

假设  $f$  是一个定义在  $\Omega$  上的函数, 区域  $\{(x, y) : y \geq f(x), \forall x \in \Omega\}$  就是  $f$  的上境图.

上境图就是函数图像上方的部分区域.

## 凸集合与凸函数

一个函数是凸函数当且仅当  $f$  的上境图是凸集合.

凸集合与凸函数有很多相对应的性质可以由这个结论来进行链接。

# 凸集合与凸函数

# 凸集合与凸函数

## 凸组合


对于任何  $n$  个点  $\{x_i\}_{i=1}^n$ , 以及权重系数  $\{w_i\}_{i=1}^n$ . 若权重系数非负  $w_i \geq 0$  而且  $\sum_{i=1}^n w_i = 1$ , 则线性组合

$$S = \sum_{i=1}^n w_i x_i$$

为一个凸组合.

凸组合的物理意义可以理解成  $n$  个重量为  $w_i$  的点的整体重心.

# 凸集合与凸函数



# 凸集合与凸函数

## 集合的凸包

$n$  个点  $\{x_i\}_{i=1}^n$  的全部凸组合就构成  $\{x_i\}_{i=1}^n$  的凸包.

## 函数的凸闭包

如果  $C$  是函数  $f$  的上境图,  $\overline{C}$  是  $C$  的凸包, 那么以  $\overline{C}$  为上境图的函数称为  $f$  的凸闭包.

# 凸集合与凸函数

## 集合的凸包的性质

若  $\bar{C}$  是  $C$  的凸闭包, 那么

- $C \subset \bar{C}$
- $C$  的支撑平面也是  $\bar{C}$  的支撑平面, 反之亦然.

## 函数的凸闭包的性质

若  $g$  是  $f$  的凸闭包, 那么

- $g \leq f$
- $\inf\{g\} = \inf f$

# 凸集合与凸函数的对应性质 (凸组合)



## 凸集合性质

假设  $\Omega$  是一个凸集合, 那么  $\Omega$  任何子集的凸包仍包含于  $\Omega$ .

## 凸函数性质: 琴生 (Jensen) 不等式

如果  $f: \Omega \rightarrow \mathbb{R}$  是一个凸函数, 则对于任何  $\{x_i \in \Omega\}_{i=1}^n$ , 以及凸组合  $\sum_{i=1}^n w_i x_i$  都有

$$\sum_{i=1}^n w_i f(x_i) \geq f\left(\sum_{i=1}^n w_i x_i\right)$$



# 话外篇：琴生 (Jensen) 不等式的推论

很多常用的不等式都是琴生不等式的推论，事实上，大部分不等式要么来自于  $x^2 \geq 0$  要么来自于琴生不等式。

## 算数集合平均不等式

对于正数  $a_1, \dots, a_n$

$$\frac{\sum_{i=1}^n a_i}{n} \geq \left( \prod_{i=1}^n a_i \right)^{\frac{1}{n}}$$

## 柯西不等式

$$\left( \sum_{i=1}^n a_i^2 \right) \left( \sum_{i=1}^n b_i^2 \right) \geq \left( \sum_{i=1}^n a_i b_i \right)^2$$

# 凸集合与凸函数

$$-\ln x \text{ 凸}$$



$$\frac{1}{x^2} \geq 0$$

$$-\ln\left(\frac{\sum a_i}{n}\right) \leq \sum \frac{-\ln a_i}{n}$$
$$\ln\left(\frac{\sum a_i}{n}\right) \geq \sum \frac{\ln a_i}{n}$$

# 凸集合与凸函数的对应性质 (集合相交)





## 凸集合性质

任意多个凸集合的交集仍是凸集合.

## 凸函数性质

- 任意多个凸函数的逐点上确界仍是凸函数.
- 固定一个凸函数的若干个变量, 所得的函数仍然是凸函数
- 凸函数的 **sublevel set** 都是凸集合.




# 凸集合与凸函数

$$f(x)$$

$$f(x) = c$$

$$\text{for } \lambda \leq C$$



# 凸集合与凸函数的对应性质 (线性组合)

## 凸集合性质


假设  $T: V \rightarrow W$  是一个线性映射, 则

- 若  $\Omega_V$  是  $V$  中的凸集合, 则  $\Omega_W = T(\Omega_V)$  是  $W$  中的凸集合.
- 若  $\Omega_W$  是  $W$  中的凸集合, 则  $\Omega_V = T^{-1}(\Omega_W)$  是  $V$  中的凸集合.

## 凸函数性质

- 凸函数的非负线性组合仍是凸函数,  $f_1, \dots, f_k$  是凸函数, 而且  $w_i \geq 0$ , 则  $\sum_{i=1}^k w_i f_i$  也是凸函数.
- 若  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  是凸函数,  $A \in \mathbb{R}^{n \times m}, b \in \mathbb{R}^n$ , 那么复合函数  $g(x) = f(Ax + b)$  还是凸函数.

# 凸集合与凸函数



# 凸集合与凸函数的对应性质 (微分)

## 凸集合性质

- 若凸集合  $\Omega$  的边界  $C$  是一个可微曲线, 则  $C$  在任意一点上的切线 (平面) 都是这个凸集合的支撑线 (平面)
- 若凸集合  $\Omega$  的边界  $C$  是一个二阶可微曲线, 则  $C$  在任意一点上的曲率向量都指向  $\Omega$  内部.

曲率向量的物理意义是加速方向或者受力方向.

## 凸函数性质

- 若一个凸函数一阶可微, 那么凸函数的一阶近似不大于函数本身.i.e.

$$f(x) \geq f(x_0) + (\nabla f(x_0))^T \cdot (x - x_0)$$

- 若一个凸函数二阶可微, 那么这个函数的二阶导数 (Hesssen 矩阵) 非负 (半正定) .

# 凸集合与凸函数



# 凸集合与凸函数的对应性质 (光学投影)

## 凸集合性质

- 若  $\Omega$  是凸集合, 那么  $\Omega$  在任何一个平面上的投影仍是凸集合 (平行光源投影)
- 若  $\Omega \subset \mathbb{R}^n$  是凸集合, 那么

$$\Omega_{\hat{n}} = \{(x_1/x_n, \dots, x_{n-1}/x_n, 1) : (x_1, \dots, x_n) \in \Omega \text{ 且 } x_n \neq 0\}$$

也是凸集合.(点光源投影)

- 若  $\Omega \subset \mathbb{R}^n$  是一个凸集合, 那么椎体  $tx : x \in \Omega, t \in \mathbb{R}_+$  也是个凸集合.(点光源)

# 凸集合与凸函数的对应性质 (光学投影)

## 凸函数性质

- 若  $f(x, y)$  是凸函数, 那么  $g(x) = \inf_{(x, y) \in \Omega} f(x, y)$ , 也是凸函数
- 若  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  是凸函数, 那么  $g(x, t) = tf(x/t): \mathbb{R}^{n+1} \rightarrow \mathbb{R}$  也是个凸函数.

# 优化问题举例:EM 算法简介与混合高斯模型

## 潜在变量 (latent variable)

一般指在所处理的问题中不能直接观测的变量

## 举例

某地希望统计当年高中入学男女学生身高分布，并分别建立正态分布模型：

- 女学生:  $M \sim N(\mu_0, \sigma_0)$
- 男学生:  $W \sim N(\mu_1, \sigma_1)$

但是测量身高时忘记了记录学生性别。此时，学生性别这一变量就成为了一个潜变量。

## 混合高斯模型举例

请问如何根据混合身高数据，估计男女学生比例，分别建立男生和女生的身高正态分布模型，并利用此模型来估计每一个样本的性别？

混合高斯模型要求对每一个高斯模型的参数进行估计，并估计单个样本服从每一个模型的概率。这既是一个统计参数估计问题，也是一个聚类问题。

## 混合高斯模型举例

用  $\tau_0, \tau_1$  分别表示男女生站总体的比例, 那么混合身高数据则服从如下分布:

$$p(x|\tau, \mu, \sigma) = \tau_0 * N(\mu_0, \sigma_0) + \tau_1 * N(\mu_1, \sigma_1)$$

此时所需估计的参数为  $\tau_0, \tau_1, \mu_0, \mu_1, \sigma_0, \sigma_1$  思考题: 如何证明这个函数是一个概率密度函数?

# 优化问题举例:EM 算法简介与混合高斯模型

作为一个有明确的概率密度函数表达式的参数估计问题，我们很自然的想到使用极大似然估计的方法：

## 极大似然估计

$$\tau, \mu, \sigma = \operatorname{argmax}_{\tau, \mu, \sigma} \sum_i p(x_i | \tau, \mu, \sigma)$$

但是这个的计算及其复杂，复杂的原因在于  $\ln$  里面有两个不同的密度函数。所以如果我们能知道每一个样本的分类，并且能够把这两个密度函数分开就好了。

# 优化问题举例:EM 算法简介与混合高斯模型

## EM 算法

- E 步骤: 对每一个样本的分类进行估计, 并且把密度函数分开到不同的  $ln$  里面去
- M 步骤: 参数估计

# 优化问题举例:EM 算法简介与混合高斯模型

## EM 算法:E 步骤

- 后验估计分类概率
- 利用凸函数的性质分离变量



# 优化问题举例:EM 算法简介与混合高斯模型

## EM 算法:M 步骤

简单的参数估计。

# 优化问题举例:EM 算法简介与混合高斯模型

block 样本

block 内容

补充内容

# 凸优化：参考资料

## 参考资料

- 非常清晰完整的经典教材：凸优化，Stephen Boyd, Lieven Vandenberghe

## 作业

- 教材：凸优化 (英文版页码与题号) p60:2.32,10,2.12,2.16,2.23,2.26;  
p113:3.1,3.2,3.12,3.21,3.36,3.39; p189:4.2,4.8,4.10,4.21  
p273:5.1,5.4,5.11,5.22,5.24

谢谢大家!