

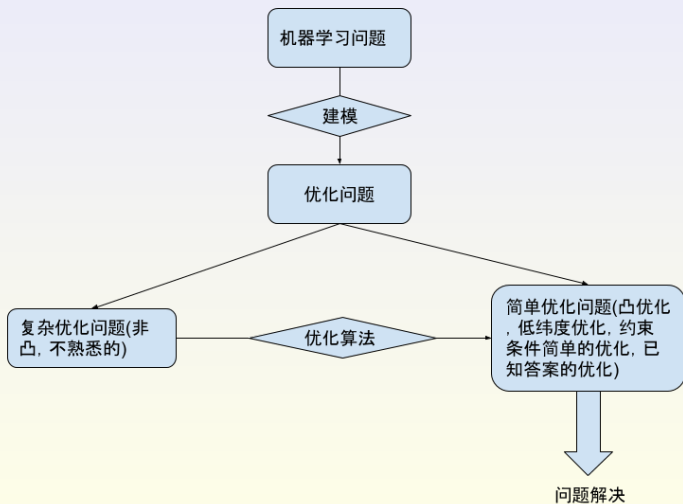
# 矩阵论与凸优化第 6 课凸优化在机器学习中的应用

管老师

七月在线

June, 2016

# 机器学习与优化



# 主要内容

## 凸优化应用举例

本节课介绍凸优化在机器学习以及图像处理的两个应用，准备过程中参考了 YouTube 上的如下资源.

- 支持向量机 (SVM)
  - MIT 公开课: [人工智能第 16 课 SVM](#)
- 压缩感知与图像处理
  - 陶哲轩演讲: [Compressed Sensing](#)

# 支持向量机 (SVM)

支持向量机是针对分类问题的一种线性分类算法

## 分类问题

通过样本的特征数据，对样本进行分类的问题。

- 医疗诊断
- 网络信息安全
- 图像识别
- ...

# 支持向量机 (SVM)

每一个样本都可以看成是特征空间  $\mathcal{R}^n$  中的一个点, 一个分类算法则将空间分为若干部分, 每部分都对应一个分类。

## 线性分类器

线性分类器泛指使用超平面来对特征空间进行分割的分类算法。

对于一些线性可分的例子来说, 可以达到分类目的的线性分类器并不唯一, 那么如何选择一个我们认为是“最好”的呢?

# 支持向量机 (SVM)

## 线性分类器的数学形式

空间  $\mathbb{R}^n$  中有可分的两个点集  $C, D$ . 线性分类器构造一个超平面  $a^T x = b$  对空间进行分割, 使得  $C$  和  $D$  分别位于这个超平面的两侧.

$$a^T p > b, \quad a^T q < b$$

这等价于存在一个正数  $t$  使得  $a^T p - b \geq t$ ,  $a^T q - b \leq -t$ , 而这个正数  $t$  一定程度上描述了两个集合被分开的程度. 所以一个比较好的想法就是希望当  $a$  是单位向量的时候,  $t$  越大越好. 这样我们就得到了一个优化问题.

# 支持向量机 (SVM)

## SVM 优化问题

最小化:  $-t$

不等条件 1:  $-a^T p_i + b \leq -t$

不等条件 2:  $a^T q_i - b \leq -t$

不等条件 3:  $-t \leq 0$

等式条件:  $|a|^2 = 1$

但是这里面  $|a|^2 = 1$  并非凸条件, 所以我们做一个变量代换  $w = a/t$ , 那么我们最大化  $t$  就等于最小化  $|w|^2$ . 于是我们得到了下面的等价优化问题。

# 支持向量机 (SVM)

## SVM 凸优化问题

$$\text{最小化: } \frac{1}{2}|w|^2$$

$$\text{不等条件 1: } -w^T p_i + b \leq -1$$

$$\text{不等条件 2: } w^T q_i - b \leq -1$$



# 支持向量机 (SVM)

为了方便表述, 将  $p_i, q_i$  统一定义为  $x_i$ , 并定义变量  $y$  使得如果  $x_i \in C$  则  $y_i = -1$ , 否则  $y_i = 1$

## SVM 凸优化问题

$$\text{最小化: } \frac{1}{2}|w|^2$$

$$\text{不等条件 1: } y_i(w^T x_i - b) + 1 \leq 0$$

# 支持向量机 (SVM)

## SVM 凸优化对偶问题: 拉格朗日量

$$L(w, b, \lambda) = \frac{1}{2}|w|^2 + \sum_i \lambda_i (y_i (w^T x_i - b) + 1)$$

对偶函数为拉格朗日量在  $w, b$  上取到的极小值, 所以我们计算  $L$  的梯度:

$$\frac{\partial}{\partial w} L = w + \sum_i \lambda_i y_i x_i$$

$$\frac{\partial}{\partial b} L = \sum_i \lambda_i y_i$$

于是我们得到对偶函数

# 支持向量机 (SVM)

## SVM 凸优化对偶问题: 对偶函数

$$\begin{aligned} g(\lambda) &= \frac{1}{2} \left( \sum_i \lambda_i y_i x_i \right)^T \left( \sum_i \lambda_i y_i x_i \right) \\ &\quad + \sum_i \lambda_i (y_i ((-\sum_i \lambda_i y_i x_i)^T x_i - b) + 1) \\ &= \sum_i \lambda_i - \frac{1}{2} \sum_i \sum_j \lambda_i \lambda_j y_i y_j x_i^T x_j \end{aligned}$$

# 支持向量机 (SVM)

进一步简化, 定义:

$$y = [y_1, y_2, \dots, y_n]^T$$

$$Y = \text{diag}(y_1, y_2, \dots, y_n)$$

$$X = [x_1, x_2, \dots, x_n]$$

$$E = [1, 1, \dots, 1]^T$$

$$K_0 = Y^T X^T X Y$$

于是

SVM 凸优化对偶问题: 对偶函数

$$g(\lambda) = \lambda^T E - \frac{1}{2} \lambda^T K_0 \lambda$$

# 支持向量机 (SVM)

## SVM 凸优化对偶问题

$$\text{最大化: } \lambda^T E - \frac{1}{2} \lambda^T K_0 \lambda$$

$$\text{不等条件: } \lambda_i \geq 0$$

$$\text{定义域: } \lambda^T y = 0$$

$K_0$  集中包含了  $x_i$  的全部信息. 不同的分类问题对应着不同的  $K_0$ . 对于非线性 SVM 问题, 所谓 **kernel** 技巧, 就是针对  $K_0$  进行变换 (此处不再详述).

# 支持向量机 (SVM)

考虑  $C$  与  $D$  的凸包  $\overline{C}$  和  $\overline{D}$

## SVM 凸集合思路

若  $p \in \overline{C}, q \in \overline{D}$ , 满足  $d(p, q) = d(\overline{C}, \overline{D})$  则, 向量  $\vec{pq}$  即为所求支撑向量。

# 支持向量机 (SVM)

定义:

$$P = [p_1, \cdots, p_{n_c}]$$

$$Q = [q_1, \cdots, q_{n_D}]$$

于是:  $X^T = [P^T, Q^T]$ , 而对于  $\lambda^T P \in \overline{C}$  与  $\mu^T Q \in \overline{D}$ , 这两点之间的距离为

$$(\lambda^T P - \mu^T Q)^T (\lambda^T P - \mu^T Q) = [\lambda^T, \mu^T] K_0 [\lambda^T, \mu^T]^T$$

# 支持向量机 (SVM)

## SVM 凸优化问题 (凸集合思路)

$$\text{最小化: } [\lambda^T, \mu^T] K_0 [\lambda^T, \mu^T]^T$$

$$\text{不等条件: } \lambda \geq 0$$

$$\text{不等条件: } \mu \geq 0$$

$$\text{等式条件: } \lambda^T E = 1$$

$$\text{等式条件: } \mu^T E = 1$$

再一次我们看到  $K_0$  集中包含了  $x_i$  的全部信息. 不同的分类问题对应着不同的  $K_0$ .

思考题: 请证明凸集合思路的 SVM 优化问题与前面的 SVM 凸优化对偶问题等价



# 压缩感知与图像处理

压缩感知 (compressive sensing) 是一个关于信号还原的理论, 其基本问题是如下的一个线性方程

## 线性代数问题

$A$  是一个  $m \times n$  的矩阵,  $b$  是一个  $m$  维向量, 求解方程  $Ax = b$ .

其中  $b$  是接收到的信号,  $x$  是待还原的信号。

## 线性方程经典结论

- i 如果  $m = n$ , 而且  $A$  是可逆的, 那么  $x = A^{-1}y$
- ii 如果  $m > n$ , 那么我们使用最小二乘进行估计  
$$x \sim (A^T A)^{-1} A^T b$$
- iii 如果  $m < n$ , 则通常解不唯一,  $x = x_0 + l, l \in \text{Null}(A)$

压缩感知关心的正是第 iii 种情况!

# 压缩感知有可能实现吗？

## 一般情况下不可能

如果  $b$  的维数小于  $x$  的维数, 一般而言, 方程  $Ax = b$  有无穷多解。所以不可能通过  $b$  来恢复  $x$ 。

## 当 $x$ 具有稀疏性的时候, 可能实现压缩感知

如果已知原信号  $x$  中只有  $S$  个元素不为零, 那么称  $x$  为  $S$ -Sparse. 在这种情况下,  $Ax = b$  有可能具有唯一一个满足  $x$  的稀疏性的解。

# 压缩感知与图像处理

## 压缩感知的理论保障

如果  $A$  的任意  $2S$  列都线性无关, 那么  $Ax = b$  的  $S$ -sparse 解具有唯一性.

## 证明

## 压缩感知的适用范围

- 接收信号  $b$  维数小于原信号  $x$  的维数
- 原信号  $x$  具有稀疏性 (Sparsity)
- 医学图像 (核磁共振, CT 成像)
- 石油探测成像
- 单像素相机
- ...

# 压缩感知与图像处理

## 压缩感知的实现

在  $Ax = b$  全部解中寻找满足稀疏性  $S$ -sparse 的解。

稀疏性是  $x$  非零元素的个数，于是得到优化问题.

# 压缩感知与图像处理

## 压缩感知优化问题

最小化:  $|x|_0$

等式条件:  $Ax - b = 0$

优化函数  $|x|_0$  并非凸函数, 很难求解。

## 压缩感知优化问题

最小化:  $|x|_2$

等式条件:  $Ax - b = 0$

优化函数  $|x|_2$  很容易求解, 但是不能得到原问题的解。

## 压缩感知优化问题

最小化:  $|x|_1$

等式条件:  $Ax - b = 0$

优化函数  $|x|_1$  是凸函数, 可以求解, 并且保留了解的**稀疏性**。



# 数值实验结果

## 参考 sklearn 举例

SVM 分类器: [sklearn SVM 举例](#)

压缩感知: [sklearn 压缩感知举例](#)

谢谢大家!