

法律声明

□ 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。

□ 课程详情请咨询

■ 微信公众号：大数据分析挖掘

■ 新浪微博：ChinaHadoop



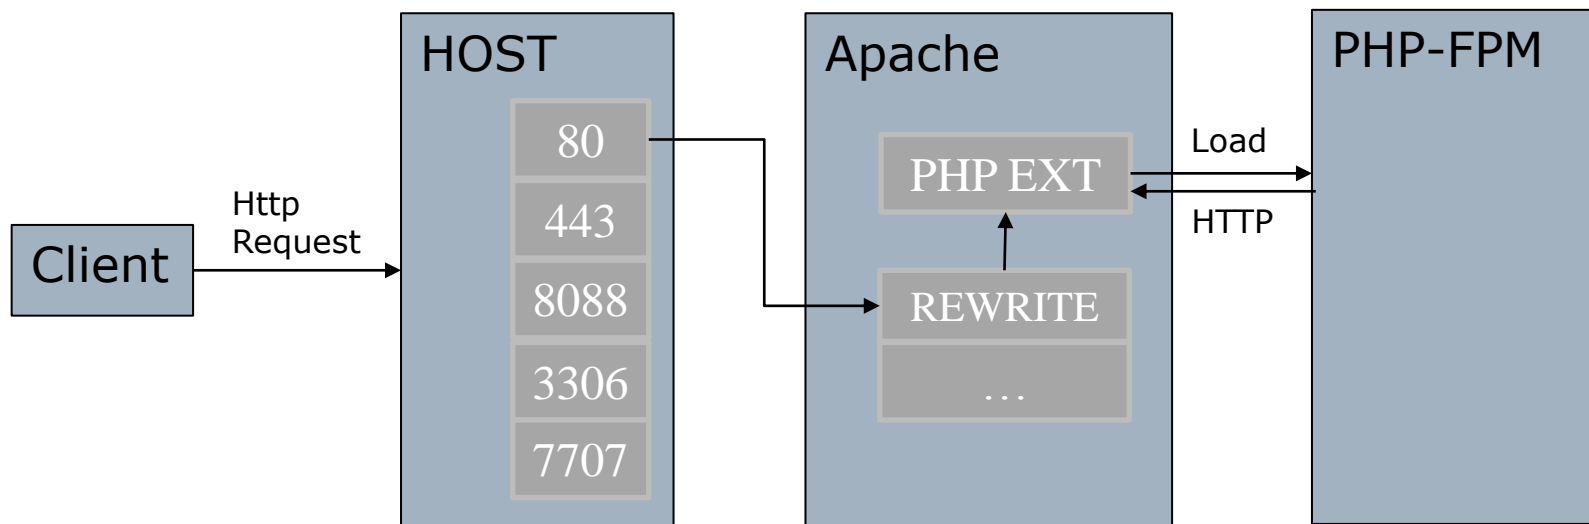
分布式爬虫

大纲

- Web 服务器
- 网站的反爬虫技术
- 应对网站的反爬策略
- 表单及登录

Web 服务器

服务器处理 Web 请求



服务器处理Web请求流程

1. 到达防火墙，对访问频次进行检查
2. 根据端口映射，到达对应的服务，例如Apache
3. 到达 Apache，通过 virtual host 查找根目录
4. 查找 .htaccess 伪静态设置，映射实际目录及文件
5. 执行脚本或提取文件
6. 确认 cookie 信息，查找用户
7. 用户权限检查
8. 执行命令，返回数据

服务器处理 Web 请求

- 伪静态：实际的文件系统结构与网络请求路径分离
- 路由过程：通常第一步是身份及权限检查
- 设置 Cookie 及 SESSIONID，保存SESSION

```
AddDefaultCharset UTF-8

<IfModule mod_rewrite.c>
    RewriteEngine On
    RewriteCond %{SERVER_PORT} !^443$
    RewriteRule ^(.*) https://$(SERVER_NAME)/public/$1 [L,R]
    RewriteRule ^api/$ api/ [L]
    RewriteRule ^api/(.*) api/$1 [L]
    RewriteRule ^$ public/ [L]
    RewriteRule /img/(.*) upload/img/$1 [L]
    RewriteRule (.*?) public/$1 [L]
</IfModule>
```

Virtual Host

```
<VirtualHost *:80>
    DocumentRoot "/Users/zhen/Sites/silkroad"
    ServerName silkroad.lo
    <Directory />
        Options FollowSymLinks Multiviews
        MultiviewsMatch Any
        AllowOverride All
        Require all granted
    </Directory>
    ErrorLog "/private/var/log/apache2/silkroad.com-error_log"
    CustomLog "/private/var/log/apache2/silkroad.com-access_log" common
</VirtualHost>

<VirtualHost *:80>
    DocumentRoot "/Users/zhen/Sites/"
    ServerName jc.lo
    <Directory />
        Options FollowSymLinks Multiviews
        MultiviewsMatch Any
        AllowOverride All
        Require all granted
    </Directory>
    ErrorLog "/private/var/log/apache2/jc.lo-error_log"
    CustomLog "/private/var/log/apache2/jc.lo-access_log" common
</VirtualHost>
```


Virtual Host

定义

- 一台服务器主机可以处理多个域名或IP
- 将不同的域名及Ip映射到不同的网站根目录

对爬虫的影响

- 不同的域名指向同一个服务器，更容易被服务器识别为爬虫（异常访问）而禁止
- 对于一个域名映射多台服务器的网站，在单机上不能并发抓取不同服务器的数据

网站如何发现爬虫？

- 单一IP非常规的访问频次
- 单一IP非常规的数据流量
- 大量重复简单的网站浏览行为
- 只下载网页，没有后续的js、css请求
- 通过一些陷阱来发现爬虫，例如一些通过CSS对用户隐藏的链接，只有爬虫才会访问

网站如何进行反爬 - UserAgent

假设我们已经确定了两类爬虫的UserAgent，它们分别是 Nutch 和 Scrapy

User-Agent: Nutch

User-Agent: Scrapy

对应反爬虫的 .htaccess 文件定义：

```
BrowserMatchNoCase Nutch bad_bot
BrowserMatchNoCase Scrapy bad_bot
Order Deny,Allow
Deny from env=bad_bot
```

Nutch Scrapy 为禁止的key，bad_bot 是定义的环境变量

网站如何进行反爬 - .htaccess

1. Check access_log file

Apache: /var/log/httpd/

```
52.78.100.100 - - [13/Feb/2017:03:22:03 +0000] "GET http://100.100.100.100/ HTTP/1.1" 200 836
52.78.100.100 - - [13/Feb/2017:03:22:03 +0000] "GET http://100.100.100.100/build/common-ef0ce496.js HTTP/1.1" 304 -
52.78.100.100 - - [13/Feb/2017:03:22:05 +0000] "GET http://100.100.100.100/build/index-04b31db5.js HTTP/1.1" 304 -
52.78.100.100 - - [13/Feb/2017:03:22:05 +0000] "GET http://100.100.100.100/favicon.ico HTTP/1.1" 200 836
52.78.100.100 - - [13/Feb/2017:03:22:09 +0000] "POST http://100.100.100.100:9702/api/map/suggestion HTTP/1.1" 200 814
52.78.100.100 - - [13/Feb/2017:03:22:09 +0000] "POST http://100.100.100.100:9702/api/map/suggestion HTTP/1.1" 200 85
52.78.100.100 - - [13/Feb/2017:03:22:10 +0000] "POST http://100.100.100.100:9702/api/map/suggestion HTTP/1.1" 200 85
```

2. Order Deny, Allow

Deny from xxx.xxx.xxx.xxx

Deny from xxx.xxx.xxx.xxx

网站如何进行反爬 - UserAgent

假设我们已经确定了两类爬虫的UserAgent，它们分别是 Nutch 和 Scrapy

User-Agent: Nutch

User-Agent: Scrapy

对应反爬虫的 .htaccess 文件定义：

```
BrowserMatchNoCase Nutch bad_bot
BrowserMatchNoCase Scrapy bad_bot
Order Deny,Allow
Deny from env=bad_bot
```

Nutch Scrapy 为禁止的key，bad_bot 是定义的环境变量

网站如何进行反爬 - Javascript

大量使用动态网页，使得爬虫的爬取难度增加，常规手段只能拿到一个基本的HTML页面，重要的数据等信息都拿不到

即使爬虫采用了 **Web** 环境来渲染网页，也会大大增加爬虫的负担与爬取的时间

同时，采用动态加载数据，对服务器的负担也会大大减轻

基于流量的拒绝

开启带宽限制模块

```
LoadModule bw_module          /usr/lib/apache/mod_bw.so
```

设置访问的最大带宽，每个Ip最多3个连接，最大1MB/s

```
BandWidthModule On
```

```
ForceBandWidthModule On
```

```
BandWidth all 1024000
```

```
MinBandwidth all -1
```

```
MaxConnection all 3
```

```
#<Location /modbw>
```

```
#  SetHandler modbw-handler
```

```
#</Location>
```

基于IP连接的拒绝

some_folder 目录 每个Ip
最多1个同时的连接，不限
制 image/* 目录的文件

```
[codesyntax lang="apache"]  
<Location /some_folder>  
MaxConnPerIP 1  
NoIPLimit image/*  
</Location>
```

/home/*/public_html 目录限制仅
限1个Ip访问，但是仅针对
audio/mpeg 格式文件

```
[codesyntax lang="apache"]  
<Directory /home/*/public_html>  
MaxConnPerIP 1  
OnlyIPLimit audio/mpeg video  
</Directory>
```


iptables 的控制

Syntax:

```
/sbin/iptables -A INPUT -p tcp --syn --dport $port -m connlimit  
--connlimit-above N -j REJECT --reject-with tcp-reset
```

Example: Limit HTTP Connections Per IP / Host

```
/sbin/iptables -A INPUT -p tcp --syn --dport 80 -m connlimit --  
connlimit-above 20 -j REJECT --reject-with tcp-reset
```

Example: Limit HTTP Connections Per IP / Host Per Second

```
iptables -A INPUT -m state --state RELATED,ESTABLISHED -m  
limit --limit 10/second --limit-burst 20 -j ACCEPT
```

当收到20个数据包后，触发访问频次限制，此时每秒最多10次连接请求，即单位时间为 100ms；如果100ms内没有收到请求，系统触发的条件就+1，也就是说如果1s钟内停止发送数据，则再次建立10次连接之内都不会激活单位计数限制

如何发现自己可能被网站识别了？

- CAPTCHA pages
- Unusual content delivery delay
- Frequent response with HTTP 404, 301 or 50x errors

301 Moved Temporarily

401 Unauthorized

403 Forbidden

404 Not Found

408 Request Timeout

429 Too Many Requests

503 Service Unavailable

动态 IP 切换技术

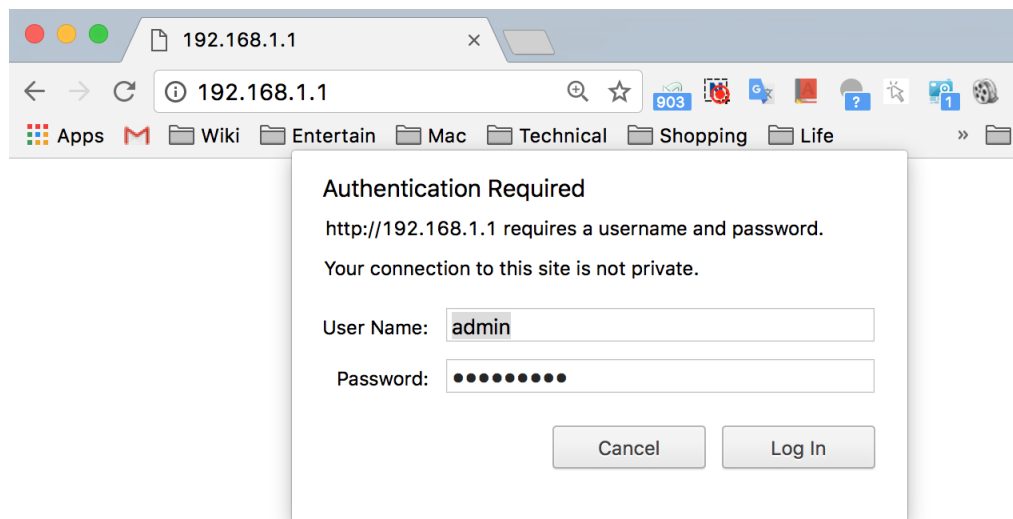
1. 模拟路由器登录
2. 通过POSTMAN查找路由器的断线、重连接口
3. 当发现IP被主机识别后，强制路由器断线、重连

路由器登录

1. 普通表单：直接通过表单发送FORM请求

2. 401 Unauthorized:

没有登录的情况下，服务器返回401，并在Header里设置 **WWW-Authenticate: Basic realm="User Visible Realm"**，客户端收到 401 同时检查到Header里包含了以上信息的情况下，会自动弹出登录框要求用户登录



路由器登录

2种实现自动登录的方法:

1. url: username:password@ip

e,g: admin:rootadmin@192.168.1.1

2. set **Authorization** field in Header:

Key: Authorization

Value: `Basic ` + base64.b64encode(`username:password`)

Authorization: Basic YWRtaW46cm9vdGFkbWlu

路由器重连

The screenshot shows the Netgear R7000 router's web interface. The 'Router Information' tab is active, displaying connection status and details. A red box highlights the '连接状态' (Connection Status) button. A red box highlights the '断开连接' (Disconnect) button. A red box highlights the 'Inspect' option in the browser's context menu. A red box highlights the 'Network' section on the right side of the interface. A red box highlights the '连接状态' (Connection Status) button in the 'Network' section.

1. 点击链接状态

2. 在弹出的小窗口邮件点击

3. 选择 Inspect

4. 点击断开连接

5. 在右侧检查窗口的 Network 选项下，查看断开连接的 API 接口及参数

连接状态	
连接时间	05:34:11
连接状态	已连接
协商	成功连接
认证	成功连接
IP地址	115.171.230.156
子网掩码	

因特网端口	
MAC 地址	C4:04:15:21:7E:C1
IP地址	115.171.230.156
连接	PPPoE
子网掩码	255.255.255.255
域名服务器	219.141.140.10 219.141.136.10

访客网络 (2.4 GHz)	
无线网络标识 (SSID)	NETGEAR-Guest
无线接入点	关

nofollow 属性

"Nofollow" provides a way for webmasters to tell search engines "Don't follow links on this page" or "Don't follow this specific link."

Originally, the nofollow attribute appeared in the page-level meta tag, and instructed search engines not to follow (i.e., crawl) any outgoing links on the page. For example:

```
<meta name="robots" content="nofollow" />
```

css 的 display 属性

The **display** CSS property specifies the type of rendering box used for an element. In HTML, default **display** property values are taken from behaviors described in the HTML specifications or from the browser/user default stylesheet. The default value in XML is inline.

`display:none` 隐藏当前块

检测display属性:

```
document.getElementById('id').style.display
```

```
document.getElementsByClassName('classname')[0].style.display
```


好的规避反爬虫检查的方法

1. 多主机策略
2. 爬的慢一点，不要攻击主机，如果发现被阻止，立即降低访问频次，设计得**smart**一点，来找到访问频次限制的临界点
3. 通过变换 **IP** 或者 代理服务器 来掩饰
4. 把爬虫放到访问频繁的主站**IP**的子网下，例如教育网
5. 频繁改变自己的 **User-Agent**
6. 探测陷阱，比如 **nofollow** 的 **tag**，或者 **display:none** 的 **CSS**
7. 如果使用了规则(**pattern**)来批量爬取，需要对规则进行组合
8. 如果可能，按照 **Robots.txt** 定义的行为去文明抓取

疑问

□ 问题答疑：<http://www.xxwenda.com/>

■ 可邀请老师或者其他人回答问题

联系我们

小象学院：互联网新技术在线教育领航者

- 微信公众号：大数据分析挖掘
- 新浪微博：ChinaHadoop

